studeersnel

Bao Cao Big Data - Đồ án cuối kì môn công nghệ dữ liệu lớn UIT - Dự đoán điểm trung bình của sinh

Công nghệ Dữ liệu lớn (Trường Đại học Công nghệ thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh)



Scan to open on Studeersnel

Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)
Studocu is not sponsored or endorsed by any college or university

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO ĐỀ TÀI

DỰ ĐOÁN ĐIỂM TRUNG BÌNH HỌC KỲ SINH VIÊN DỰA TRÊN DỮ LIỆU HỌC TẬP QUÁ KHỨ

MÔN HỌC:

CÔNG NGHỆ DỮ LIỆU LỚN – IE212.P22

Nhóm sinh viên thực hiện:

1. Hứa Xuân Vinh MSSV: 22521667
2. Phạm Mạnh Kha MSSV: 22520600

Giảng viên hướng dẫn: TS. Hà Minh Tân

TP. HỒ CHÍ MINH, THÁNG 04 NĂM 2025

studeersnel

Scan to open on Studeersnel

Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

……..

studeersnel

Scan to open on Studeersnel

Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

LỜI CẢM ƠN

Em xin chân thành cảm ơn giảng viên, tiến sĩ Hà Minh Tân đã hướng dẫn và hỗ trợ em trong suốt quá trình thực hiện đồ án môn học "Công nghệ dữ liệu lớn". Những kiến thức quý báu và sự tận tâm của thầy đã giúp em hoàn thành đồ án này một cách tốt nhất.

Trong suốt thời gian làm đồ án, thầy đã giúp em hiểu rõ hơn về các khái niệm và xu hướng mới trong lĩnh vực dữ liệu lớn, cung cấp những chỉ dẫn quý báu và luôn khuyến khích em sáng tạo trong quá trình làm việc. Những phản hồi chi tiết và chính xác của thầy đã giúp em cải thiện và hoàn thiện đồ án, đồng thời mở rộng tầm hiểu biết của em về các vấn đề lý thuyết và thực tiễn trong lĩnh vực này.

Em cũng đặc biệt cảm ơn thầyvì đã tạo ra một môi trường học tập tích cực và thân thiện, nơi em có thể thoải mái trao đổi ý tưởng, học hỏi và phát triển kỹ năng nghiên cứu độc lập. Sự hướng dẫn của thầy không chỉ giúp em hoàn thành đồ án này mà còn tạo động lực cho em tiếp tục theo đuổi và phát triển những nghiên cứu trong tương lai.

Em xin kính chúc thầy sức khỏe dồi dào, thành công trong công tác giảng dạy và nghiên cứu. Em rất biết ơn sự giúp đỡ và những bài học quý giá mà thầy đã chia sẻ.

studeersnel

Scan to open on Studeersnel

Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

MỤC LỤC

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI....7
1.1. Động lực chọn đề tài....7
1.2. Mô tả bài toán....7
1.3. Mục tiêu đề tài và phạm vi bài toán....8
CHƯƠNG 2. TÌM HIỂU ĐỀ TÀI LIÊN QUAN....10
2.1. Student performance prediction using machine learning algorithms [1]....10
2.2. Predicting student performance by using data mining methods for classification [2]....10
2.3. Dự báo kết quả học tập bằng kỹ thuật học sâu với mạng nơ-ron đa tầng [3]....11
CHƯƠNG 3. BỘ DỮ LIỆU....13
3.1. Giới thiệu bộ dữ liệu sử dụng....13
3.2. Quy trình EDA....13
3.2.1. Thống kê mô tả....13
3.2.2. Phân tích đơn biến....20
3.2.1. Phân tích đa biến....24
3.3. Nhận xét chất lượng bộ dữ liệu trước và sau khi xử lý....25
3.3.1. Kích thước và cấu trúc:....25
3.3.2. Kiểu dữ liệu....26
3.3.3. Giá trị thiếu (NaN)....26
3.3.4. Dữ liệu bất thường (Outliers/Invalid Data)....27
3.3.5. Dữ liệu bất thường/Không hợp lệ....28
3.3.6. Phân phối các cột dtbhk trước và sau khi xử lý....28
3.3.7. Tổng quan chất lượng bộ dữ liệu trước và sau khi xử lý....32
3.4. Phương pháp tổ chức dữ liệu thực nghiệm....33
3.4.1. Phân chia dữ liệu theo học kỳ....33
3.4.2. Xử lý các giá trị thiếu và không hợp lệ....33
3.4.3. Chia dữ liệu train, test....35
3.4.4. Mục tiêu tổ chức....36
CHƯƠNG 4. PHƯƠNG PHÁP ĐỀ XUẤT....36
4.1. Mô hình....36
4.1.1. Linear Regression....36
4.1.2. XGBoost....38

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

4.1.3. Random Forest....39
4.2. Kiến trúc hệ thống....41
4.2.1. Công nghệ sử dụng....41
4.2.2. Kiến trúc....42
CHƯƠNG 5. THỰC NGHIỆM....43
5.1. Độ đo đánh giá....43
5.1.1. Giới thiệu....43
5.1.2. Các Độ đo Đánh giá Chính....43
5.1.3. Lựa chọn Độ đo Đánh giá....45
5.2. Thông số chi tiết các thuật toán....46
5.2.1. Linear Regression with Cross validation....46
5.2.2. Random Forest....46
5.2.3. XGboost....46
5.3. Đánh giá thực nghiệm....47
5.3.1. Kết quả thực nghiệm....47
5.3.2. Nhận xét....47
5.4. Ứng dụng thực nghiệm....49
CHƯƠNG 6. KẾT LUẬN....51
6.1. Tóm tắt đề tài....51
6.2. Đóng góp của đề tài....51
6.3. Hướng phát triển đề tài....51

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

DANH MỤC HÌNH ẢNH

Hình 2: Biểu đồ phân bố giới tính.....20
Hình 3: Biểu đồ phân bố học kỳ.....21
Hình 4: Biểu đồ phân bố năm học.....22
Hình 5: Biểu đồ Histogram thể hiện tỷ lệ sinh viên ở các mức điểm trung bình học kỳ.....23
Hình 6: Biểu đồ Boxplot thể hiện mức độ tập trung của điểm trung bình học kỳ.....24
Hình 6: Kết quả phân tích hồi quy.....25
Hình 10: Phân phối điểm các học kỳ.....31
Hình 11: Random Forest.....40
Hình 12: Kiến trúc hệ thống.....42
Hình 14: Giao diện chính của ứng dụng.....49
Hình 15: Demo thuật toán Linear Regression.....49
Hình 16: Demo thuật toán Random Forest.....50
Hình 17: Demo thuật toán XGBoost.....50

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

DANH MỤC BẢNG

Bảng 1: Mô tả bộ dữ liệu sử dụng....13
Bảng 2: Thống kê mô tả EDA....14
Bảng 3: Tần số và tuần suất năm sinh....17
Bảng 4: Tần số và tần suất giới tính....17
Bảng 5: Tần số và tầ suất học kỳ....18
Bảng 6: Tần số và tần suất năm học....18
Bảng 7: Tần số và tần suất điểm trung bình....19
Bảng 8: Kiểu dữ liệu của các cột....26
Bảng 9: Giá trị NaN....27
Bảng 10: Dữ liệu bất thường....28
Bảng 11: Dữ liệu bất thường và không hợp lệ....28
Bảng 12: Tổng quan chất lượng bộ dữ liệu....33
Bảng 13 : Tham số Linear Regression....46
Bảng 14: Tham số Random Forest....46
Bảng 15: Tham số XGboost....46
Bảng 16 : Kết quả thực nghiệm....47

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Động lực chọn đề tài

Trong bối cảnh giáo dục ngày càng chú trọng vào việc nâng cao chất lượng đào tạo, việc phân tích và dự đoán kết quả học tập của sinh viên dựa trên dữ liệu lịch sử đang trở thành một trong những xu hướng quan trọng. Đề tài "**Dự đoán điểm trung bình học kỳ sinh viên dựa trên dữ liệu học tập quá khứ**" không chỉ góp phần hỗ trợ nhà trường trong việc đánh giá hiệu quả học tập mà còn cung cấp thông tin hữu ích cho sinh viên trong việc định hướng học tập cá nhân.

Sử dụng bộ dữ liệu từ sinh viên Đại học Công nghệ Thông tin (UIT), nghiên cứu này áp dụng các phương pháp học máy để xây dựng mô hình dự đoán điểm trung bình học kỳ. Bộ dữ liệu phản ánh chi tiết các yếu tố ảnh hưởng đến kết quả học tập, bao gồm điểm số, số tín chỉ, và lịch sử học tập của sinh viên. Qua đó, báo cáo không chỉ tập trung vào việc xây dựng mô hình dự đoán mà còn phân tích các yếu tố chính ảnh hưởng đến kết quả học tập, góp phần cung cấp cơ sở cho các giải pháp cải thiện hiệu quả giáo dục trong tương lai.

Nội dung báo cáo sẽ trình bày chi tiết các bước từ xử lý dữ liệu, xây dựng mô hình, đến đánh giá hiệu quả dự đoán, nhằm mang lại cái nhìn tổng quan và giá trị ứng dụng thực tiễn của nghiên cứu.

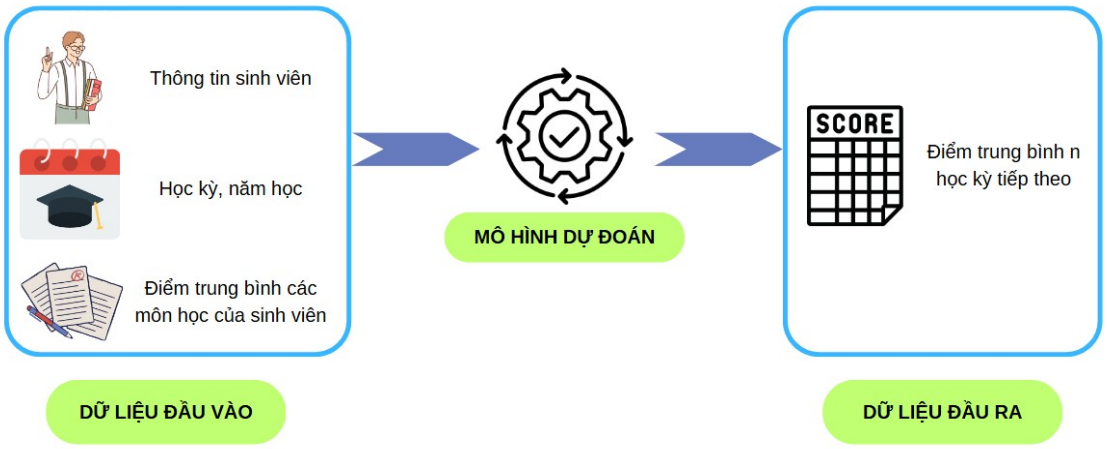
1.2. Mô tả bài toán

Bài toán "Dự đoán điểm trung bình học kỳ sinh viên dựa trên dữ liệu học tập quá khứ" là một bài toán thuộc lĩnh vực học máy (machine learning), trong đó mục tiêu là xây dựng mô hình dự đoán điểm trung bình của sinh viên trong các học kỳ tiếp theo dựa trên dữ liệu học tập ở các học kỳ trước. Mô hình dự đoán này không chỉ giúp sinh viên nhận diện được xu hướng học tập của mình mà còn hỗ trợ nhà trường trong việc tư vấn học tập và

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

phát triển chiến lược giáo dục hiệu quả. Đầu vào (input) và đầu ra (output) của bài toán được mô tả như sau:

- **Input:** các thông tin liên quan đến sinh viên UIT như điểm trung bình, học kỳ, năm học và các đặc điểm khác trong lịch sử học tập.
- **Output:** điểm trung bình dự đoán của sinh viên trong một học kỳ tiếp theo.



Hình 1. Mô hình bài toán

1.3. Mục tiêu đề tài và phạm vi bài toán

Mục tiêu của đề tài là phát triển một mô hình dự đoán điểm trung bình các học kỳ tiếp theo của sinh viên dựa trên dữ liệu lịch sử học tập, với độ chính xác cao và tốc độ thực thi nhanh, nhằm đáp ứng yêu cầu từ phía người dùng. Độ chính xác được ưu tiên hàng đầu vì đây là yếu tố quan trọng để đưa ra những quyết định có ý nghĩa trong học tập và định hướng nghề nghiệp của sinh viên.

Nghiên cứu tập trung vào việc thu thập và phân tích các thông tin liên quan đến kết quả học tập của sinh viên, bao gồm điểm trung bình các học kỳ, học kỳ và các đặc điểm khác trong khoảng thời gian giữa các kỳ học. Từ đó, các kỹ thuật học máy sẽ được áp dụng để xây dựng mô hình dự đoán điểm trung bình cho các học kỳ tiếp theo dựa trên các dữ liệu này.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Kết quả của nghiên cứu sẽ là một mô hình có khả năng dự đoán chính xác và nhanh chóng, áp dụng hiệu quả cho nhiều đối tượng sinh viên và tại các trường học khác nhau. Bên cạnh đó, nghiên cứu còn cung cấp các công cụ hỗ trợ cho giáo viên và nhà quản lý giáo dục trong việc đưa ra các giải pháp phù hợp nhằm nâng cao kết quả học tập của sinh viên.

Phạm vi thực hiện bao gồm:

- Dữ liệu được thu thập từ sinh viên sau khóa 8 của trường Đại học Công nghệ Thông tin – Đại học Quốc gia TP.HCM.
- Mô hình áp dụng cho sinh viên đã hoàn thành ít nhất một kỳ học để đảm bảo đủ dữ liệu lịch sử. Dự đoán được giới hạn ở các kỳ học tiếp theo trong phạm vi chương trình đào tạo cử nhân thông thường.
- Ứng dụng các thuật toán học máy như hồi quy tuyến tính, hồi quy đa thức, cây quyết định,... Sử dụng các công cụ như Python, các thư viện học máy.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

CHƯƠNG 2. TÌM HIỂU ĐỀ TÀI LIÊN QUAN

2.1. Student performance prediction using machine learning algorithms [1]

Giáo dục là yếu tố quan trọng đối với cuộc sống hiệu quả và cung cấp các nguồn lực cần thiết. Với sự ra đời của công nghệ như trí thông minh nhân tạo, các tổ chức giáo dục đại học đang kết hợp công nghệ vào các phương pháp giảng dạy truyền thống. Dự đoán thành công trong học tập đã thu hút sự quan tâm trong giáo dục vì thành tích học tập tốt sẽ cải thiện thứ hạng của trường đại học và tăng cơ hội việc làm cho sinh viên. Các tổ chức học tập hiện đại phải đối mặt với những thách thức trong việc phân tích hiệu suất, cung cấp nền giáo dục chất lượng cao, xây dựng chiến lược đánh giá hiệu suất của sinh viên và xác định nhu cầu trong tương lai.

Bài báo được viết bởi Esmael Ahmed, xuất bản ngày 30 tháng 4 năm 2024. Nghiên cứu tập trung vào dự đoán kết quả học tập của sinh viên bằng các thuật toán học máy. Mục tiêu chính là cải thiện độ chính xác của mô hình dự đoán để hỗ trợ giáo dục. Tác giả sử dụng dữ liệu từ Wollo University (2017-2022) với 32,005 bản ghi sau khi xử lý dữ liệu, áp dụng các thuật toán như K-Means, Cây quyết định, SVM, KNN, và Naive Bayes với kỹ thuật điều chỉnh tham số.

Nghiên cứu này phát hiện ra rằng thuật toán SVM có kết quả dự đoán tốt nhất sau khi điều chỉnh tham số, với tỷ lệ chính xác 96%. Các nhà nghiên cứu đã kiểm tra các chức năng của SVM, Cây quyết định, Naive Bayes và bộ phân loại KNN. Kết quả của việc điều chỉnh tham số đã làm tăng đáng kể độ chính xác của bốn mô hình dự đoán. Độ chính xác dự đoán của mô hình Naive Bayes là thấp nhất khi so sánh với các phương pháp dự đoán khác, vì nó giả định mối quan hệ độc lập mạnh mẽ giữa các tính năng.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

2.2. Predicting student performance by using data mining methods for classification [2]

Các phương pháp khai thác dữ liệu thường được triển khai tại các trường đại học tiên tiến ngày nay để phân tích dữ liệu có sẵn và trích xuất thông tin và kiến thức để hỗ trợ ra quyết định. Bài báo này trình bày bởi Dorina Kabakchieva với các kết quả ban đầu từ một dự án nghiên cứu khai thác dữ liệu được triển khai tại một trường đại học Bulgaria, nhằm mục đích tiết lộ tiềm năng cao của các ứng dụng khai thác dữ liệu cho quản lý trường đại học.

Dữ liệu được lấy từ hai nguồn: quá trình tuyển sinh và quá trình học tập của sinh viên. Dữ liệu được làm sạch, chuyển đổi và chuẩn bị để phù hợp với quá trình phân tích. Nghiên cứu sử dụng các thuật toán phân loại phổ biến trong WEKA như: Cây quyết định, Bayesian (Naive Bayes và Bayes Net), KNN, và 2 rule learner (OneR và JRip).

Kết quả đạt được bằng cách áp dụng các thuật toán khai thác dữ liệu đã chọn để phân loại trên dữ liệu mẫu của trường đại học cho thấy tỷ lệ dự đoán không đáng kể (dao động trong khoảng 52-67%). Hơn nữa, các bộ phân loại thực hiện khác nhau đối với năm lớp. Các thuộc tính dữ liệu liên quan đến Điểm tuyển sinh đại học của sinh viên và Số lần trượt trong kỳ thi đại học năm nhất là một trong những yếu tố ảnh hưởng nhiều nhất đến quá trình phân loại.

2.3. Dự báo kết quả học tập bằng kỹ thuật học sâu với mạng nơ-ron đa tầng [3]

Dự báo kết quả học tập là một chủ đề đang được quan tâm trong lĩnh vực giáo dục đào tạo. Dự báo sớm kết quả học tập có thể giúp sinh viên lựa chọn học phần phù hợp với năng lực cá nhân, giúp nhà quản lý và giảng viên xác định được những sinh viên cần được quan tâm hỗ trợ nhiều hơn để hoàn thành tốt học phần, giảm tình trạng cảnh báo học vụ hoặc buộc thôi học do kết quả học tập kém, từ đó tiết kiệm được thời gian chi phí cho cả sinh viên, gia đình, nhà trường và xã hội. Lưu Hoài Sang và các cộng sự đề xuất

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

một phương pháp dự báo kết quả học tập của sinh viên bằng kỹ thuật học sâu nhằm khai thác cơ sở dữ liệu trong hệ thống quản lý sinh viên tại các trường đại học.

Bài nghiên cứu sử dụng kỹ thuật học sâu với mạng nơ-ron truyền thẳng đa tầng (multi layer perceptron - MLP) để xây dựng mô hình dự đoán kết quả học tập của sinh viên đối với các học phần mới dựa trên kết quả của các học phần trước đó đã học. Ngoài ra, để cải thiện kết quả dự đoán, họ cũng xem xét một số thông tin khác như điểm tuyển sinh, ngành học, giảng viên,… để đưa vào mô hình đề xuất.

Dữ liệu thu thập sau khi tiền xử lý được chia thành hai tập dữ liệu huấn luyện (train) và kiểm tra (test) theo trình tự thời gian. Dữ liệu điểm giai đoạn đầu dùng làm tập train, giai đoạn sau dùng làm tập test.

Để tránh tính ngẫu nhiên của giải thuật, mỗi phương pháp được thực hiện 10 lần và tính kết quả trung bình độ lỗi trên 10 lần chạy. Kết quả cho thấy mô hình đề xuất đã cải thiện được độ lỗi so với các phương pháp trước đây sử dụng trong dự đoán kết quả học tập. Kết quả của mô hình MLP cho kết quả tốt nhất ở cả 2 độ đo, trong đó với độ đo MAE, mô hình này cho kết quả vượt trội so với những phương pháp còn lại. Mô hình dựa vào điểm trung bình của sinh viên cho kết quả kém nhất, trong khi mô hình ItemKNN có kết quả gần tương đương với mô hình đề xuất, trong khi kết quả của mô hình Matrix Factorization đứng ở vị trí “trung bình” trong tất cả các phương pháp được khảo sát.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

CHƯƠNG 3. BỘ DỮ LIỆU

3.1. Giới thiệu bộ dữ liệu sử dụng

Bộ dữ liệu nhóm sử dụng trong quá trình thực nghiệm đã được xử lý và gán nhãn bằng cách kết hợp các file dữ liệu:

- sinhvien_dtb_hocky.xlsx
- 01.sinhvien.xlsx

Quy trình chuẩn bị dữ liệu được thực hiện theo trình tự sau:

Sau quá trình xử lý và kết hợp dữ liệu của các file dữ liệu. Nhóm xây dựng được bộ dữ liệu chứa kết quả của sinh viên UIT trong 8 học kỳ chính. Bộ dữ liệu raw gồm 6 cột dữ liệu và 80202 mẫu dữ liệu.

STT	Tên cột	Mô tả	Kiểu giá trị
1	mssv	Mã số sinh viên	string
2	namsinh	Năm sinh của sinh viên	int
3	gioitinh	Giới tính (0 = Nam, 1 = Nữ, -1 = Không rõ)	int
4	namhoc	Năm học (ví dụ: 2021)	int
5	hocky	Học kỳ (1 = Học kỳ 1, 2 = Học kỳ 2)	int
6	dtbhk	Điểm trung bình học kỳ	float

Bảng 1: Mô tả bộ dữ liệu sử dụng

3.2. Quy trình EDA

3.2.1. Thống kê mô tả

1. Đối với các thuộc tính số (Numerical/Quantitative Variables)

Thuộc tính	Count	Mean	Std Dev	Min	25%	50%	75%	Max
namsinh	80202	1604.82	794.46	0	1995	1997	2000	2001
gioitinh	80202	0.50	0.8	-1	0	1	1	1
hocky	80202	1.43	0.49	1	1	1	2	2

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

namhoc	80202	2018.54	2.43	2013	2017	2019	2021	2022
dtbhk	80202	6.75	2.0	0	6.13	7.28	8.08	10

Bảng 2: Thống kê mô tả EDA

Nhận xét và Phân tích:

- **Thuộc tính namsinh (Năm sinh):**
  - Mặc dù thuộc tính này có đủ 80,202 bản ghi, các giá trị thống kê cho thấy vấn đề nghiêm trọng về chất lượng dữ liệu.
  - Giá trị nhỏ nhất (Min) là **0**, đây là một năm sinh không hợp lệ.
  - Giá trị trung bình (Mean) rất thấp (1604.82) và độ lệch chuẩn (Std Dev) rất lớn (794.46), cả hai chỉ số này đều bị bóp méo đáng kể bởi sự tồn tại của các giá trị không hợp lệ như 0 và có thể các giá trị bất thường khác.
  - Tuy nhiên, các tứ phân vị (25% = 1995, 50% = 1997, 75% = 2000) và giá trị lớn nhất (Max = 2001) lại cho thấy phạm vi năm sinh hợp lý của phần lớn sinh viên trong tập dữ liệu.
  - Sự chênh lệch lớn giữa giá trị trung bình và trung vị (Median=1997) càng khẳng định phân bố của thuộc tính này bị ảnh hưởng nặng nề bởi các giá trị bất thường ở phía thấp.
  - Điều này nhấn mạnh sự cần thiết phải làm sạch thuộc tính namsinh, loại bỏ hoặc xử lý các bản ghi có giá trị không hợp lệ.
- **Thuộc tính gioitinh (Giới tính):**
  - Thuộc tính này cũng có đủ 80,202 bản ghi.
  - Giá trị nhỏ nhất (Min) là **-1**, đây là một giá trị không hợp lệ cho thuộc tính giới tính (nếu giả định mã hóa là 0 và 1).
  - Độ lệch chuẩn (Std Dev) là 0.8. Đối với một biến nhị phân lý tưởng (chỉ có 0 và 1), độ lệch chuẩn tối đa là 0.5. Độ lệch chuẩn cao hơn 0.5 cho thấy sự tồn tại của các giá trị khác ngoài 0 và 1 (trong trường hợp này là -1).

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- Giá trị trung bình (Mean) là 0.50. Nếu bỏ qua giá trị không hợp lệ (-1), giá trị này sẽ gợi ý rằng tỷ lệ giới tính giữa các bản ghi là **khá cân bằng**, gần 50/50.
- Như vậy, thuộc tính gioitinh cũng chứa dữ liệu không hợp lệ (-1) cần được xử lý trước khi phân tích hoặc sử dụng cho mô hình.

- **Thuộc tính hocky (Học kỳ):**
  - Thuộc tính này có dữ liệu trong phạm vi mong đợi (1 và 2).
  - Giá trị nhỏ nhất (Min) là 1 và giá trị lớn nhất (Max) là 2, là các giá trị hợp lệ cho học kỳ.
  - Độ lệch chuẩn (Std Dev) rất thấp (0.49), điều này hợp lý vì dữ liệu chỉ tập trung ở hai giá trị 1 và 2.
  - Giá trị trung bình (Mean = 1.43) và trung vị (Median = 1) cho thấy có hơi nhiều bản ghi thuộc Học kỳ 1 so với Học kỳ 2 trong tập dữ liệu.
  - Nhìn chung, thuộc tính hocky có vẻ sạch và không có vấn đề rõ ràng dựa trên các thống kê mô tả.
- **Thuộc tính namhoc (Năm học):**
  - Thuộc tính này có dữ liệu bao gồm các năm học từ 2013 đến 2022.
  - Giá trị trung bình (Mean = 2018.54) và trung vị (Median = 2019) nằm trong phạm vi hợp lý của các năm học.
  - Độ lệch chuẩn (Std Dev = 2.43) cho thấy sự phân tán của các bản ghi qua các năm học này.
  - Sự gần nhau giữa giá trị trung bình và trung vị cho thấy phân bố các bản ghi theo năm học khá cân bằng hoặc chỉ hơi lệch nhẹ trong giai đoạn 2013-2022.
  - Thuộc tính namhoc cũng có vẻ sạch dựa trên các thống kê mô tả.
- **Thuộc tính dtbhk (Điểm trung bình học kỳ):**
  - Các giá trị nằm trong phạm vi hợp lệ của thang điểm (từ 0 đến 10), với Min = 0 và Max = 10.
  - Điểm trung bình học kỳ của toàn bộ tập dữ liệu là **6.75**.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- Độ lệch chuẩn (Std Dev) là 2.0, cho thấy sự **biến động đáng kể** trong điểm số trung bình học kỳ giữa các bản ghi.
- Có sự khác biệt rõ rệt giữa giá trị trung bình (Mean = 6.75) và giá trị trung vị (Median = 7.28). Giá trị trung vị cao hơn giá trị trung bình là một dấu hiệu mạnh mẽ cho thấy phân bố của điểm trung bình học kỳ bị **lệch trái (left-skewed)**. Điều này có nghĩa là phần lớn điểm tập trung ở phía cao hơn so với giá trị trung bình, và có một số ít bản ghi có điểm rất thấp kéo giá trị trung bình xuống.
- Các tứ phân vị (Q1=6.13, Q2=7.28, Q3=8.08) cung cấp thêm chi tiết về phân bố, cho thấy 50% bản ghi có điểm trong khoảng từ 6.13 đến 8.08.

2. Đối với các thuộc tính phân loại (Categorical Variables)

a. Năm sinh

Năm sinh	Tần số (Count)	Tần suất (%)
0	15786	19.682
1985	11	0.013
1986	7	0.008
1988	2	0.002
1989	8	0.009
1990	8	0.009
1991	52	0.064
1992	165	0.205
1993	188	0.234
1994	775	0.966
1995	7961	9.926
1996	8430	10.51
1997	8757	10.918

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

1998	7818	9.747
1999	8705	10.853
2000	10615	13.235
2001	10914	13.608

Bảng 3: Tần số và tuần suất năm sinh

Nhận xét: Phân tích tần suất xác nhận vấn đề nghiêm trọng với thuộc tính namsinh đã thấy trong thống kê mô tả. Giá trị **0** chiếm một tỷ lệ đáng kể, lên tới **19.682%** tổng số bản ghi. Đây là dữ liệu không hợp lệ rõ ràng và cần được xử lý (loại bỏ hoặc gán lại giá trị khuyết thiếu nếu phù hợp với mục tiêu phân tích). Các năm sinh hợp lệ tập trung chủ yếu trong giai đoạn **1995 đến 2001**, chiếm phần lớn còn lại của tập dữ liệu. Các năm sinh trước năm 1995 có số lượng rất nhỏ. Sự phân bố tần suất này làm rõ sự không nhất quán và vấn đề chất lượng dữ liệu của thuộc tính namsinh.

b. **Giới tính**

Giới tính	Tần số (Count)	Tần suất (%)
1	56406	70.32
-1	15786	19.68
0	8010	9.98

Bảng 4: Tần số và tần suất giới tính

Nhận xét: Phân tích tần suất cho gioitinh làm rõ vấn đề về chất lượng và sự mất cân bằng dữ liệu. Giá trị **-1** xuất hiện ở gần **20%** số bản ghi (19.68%), xác nhận đây là một mã giới tính không hợp lệ và là một vấn đề dữ liệu cần xử lý. Đối với các bản ghi có giá trị hợp lệ (0 và 1), có sự mất cân bằng rõ rệt: mã **1 chiếm tới 70.32%**, trong khi mã **0 chỉ chiếm 9.98%**. Điều này cho thấy dữ liệu được thu thập bị lệch về một nhóm giới tính nhất định đối với các bản ghi hợp lệ.

c. **Học kỳ**

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Học kỳ	Tần số (Count)	Tần suất (%)
1	45013	56.124
2	35189	43.875

Bảng 5: Tần số và tầ suất học kỳ

Nhận xét: Thuộc tính hocky chỉ chứa hai giá trị hợp lệ là 1 và 2. Số lượng bản ghi ở Học kỳ 1 (56.124%) nhiều hơn đáng kể so với Học kỳ 2 (43.875%). Mặc dù không có vấn đề về chất lượng dữ liệu (không có giá trị bất thường), sự phân bố không đồng đều này cần được lưu ý trong các phân tích hoặc mô hình hóa sau này, đặc biệt nếu "học kỳ" là một yếu tố quan trọng.

d. Năm học

Năm học	Tần số (Count)	Tần suất (%)
2013	1856	2.31
2014	3712	4.62
2015	5522	6.88
2016	7249	9.03
2017	8233	10.26
2018	9452	11.78
2019	10818	13.48
2020	12105	15.09
2021	13300	16.58
2022	7955	9.91

Bảng 6: Tần số và tần suất năm học

Nhận xét: Tập dữ liệu bao gồm các bản ghi trải dài trên 10 năm học, từ 2013 đến 2022. Số lượng bản ghi nhìn chung có xu hướng tăng đều đặn từ năm 2013 đến năm 2021, với năm 2021 có số lượng bản ghi cao nhất (16.58%). Sau đó, số lượng giảm đáng kể trong năm 2022 (9.91%). Điều này có thể phản ánh sự gia tăng về số lượng sinh viên theo dõi

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

hoặc thay đổi trong quy trình thu thập dữ liệu qua các năm. Phân bố này cho thấy dữ liệu có xu hướng tập trung nhiều hơn vào các năm học gần đây.

e. Điểm trung bình

Điểm trung bình học kỳ	Tần số (Count)	Tần suất (%)
0	2919	3.63
1	962	1.19
2	1304	1.62
3	2076	2.58
4	3495	4.35
5	7295	9.09
6	14869	18.53
7	23576	29.39
8	20397	25.43
9	3285	4.09
10	24	0.029

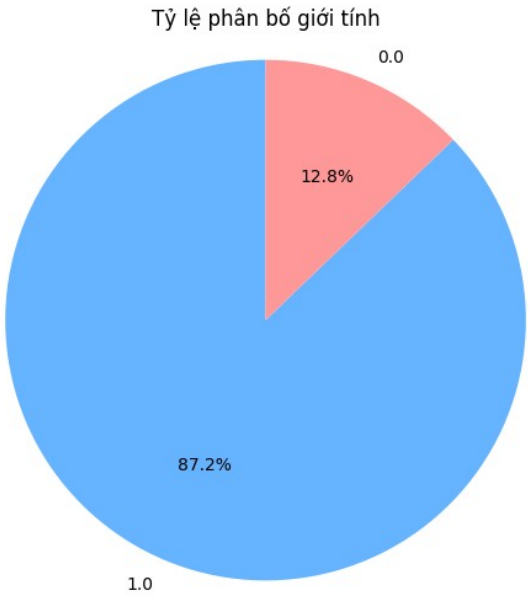
Bảng 7: Tần số và tần suất điểm trung bình

Nhận xét: Phân tích tần suất theo điểm trung bình (làm tròn) củng cố nhận định về phân bố của dtbhk. Điểm số tập trung chủ yếu ở nhóm điểm từ **6 đến 8**, chiếm tỷ lệ rất cao (18.53% + 29.39% + 25.43% = ~73.35%). Điểm 7 là phổ biến nhất (29.39%), tiếp theo là điểm 8 (25.43%) và điểm 6 (18.53%). Các điểm thấp (0-5) có tần suất thấp hơn nhiều, mặc dù điểm 0 vẫn chiếm tỷ lệ đáng kể (3.63%). Điểm tuyệt đối 10 rất hiếm gặp (0.029%). Hình dạng phân bố này xác nhận rõ ràng rằng dtbhk có **phân bố lệch trái (left-skewed)**, với đỉnh nằm ở các điểm cao và "đuôi" kéo dài về phía các điểm thấp.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

3.2.2. Phân tích đơn biến

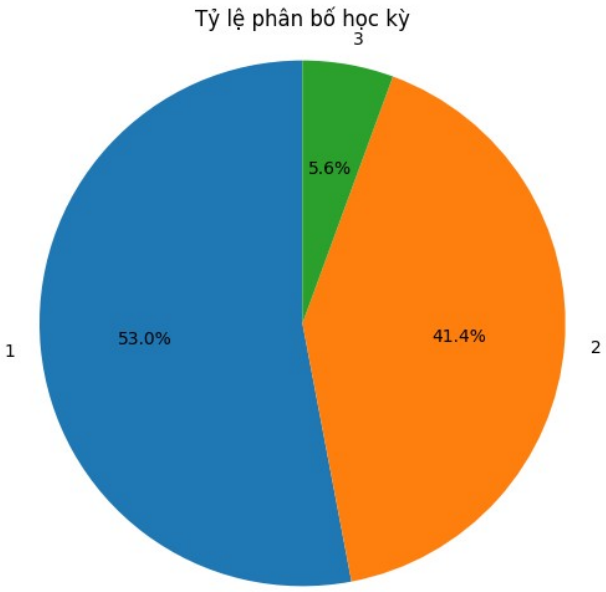
Thuộc tính **gioitinh** là dữ liệu phân loại, thể hiện giới tính của sinh viên. Thuộc tính này giúp phân tích sự cân bằng hoặc mất cân bằng giới tính trong bộ dữ liệu. Giá trị phân loại bao gồm: Nam (1.0) và Nữ (0.0). Kết quả phân tích cho thấy giới tính Nam chiếm 87.2% và giới tính nữ chiếm 12.8%.



Hình 2: Biểu đồ phân bố giới tính

Biểu đồ phân bố gioitinh: Bộ dữ liệu có sự mất cân bằng giới tính rõ rệt, với phần lớn sinh viên là nam (87.2%). Điều này có thể ảnh hưởng đến việc phân tích sau này và cần được xem xét trong quá trình xây dựng mô hình.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



Hình 3: Biểu đồ phân bố học kỳ

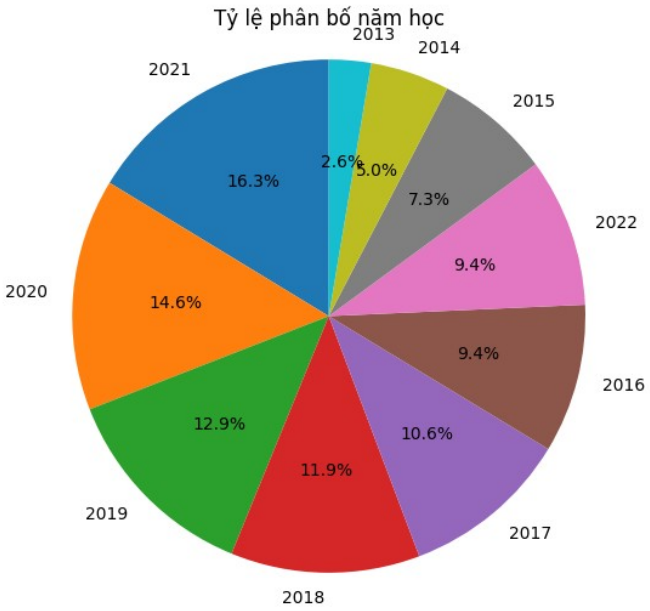
Thuộc tính hocky là dữ liệu số, thể hiện thứ tự kỳ học của sinh viên trong năm, các giá trị bao gồm 1,2,3 tương ứng với 3 kì trong năm

Biểu đồ phân bố hocky: Hầu hết sinh viên tập trung vào học kỳ 2 (41.4%) và học kỳ 1 (53%), trong khi học kỳ 3 chiếm tỷ lệ rất nhỏ (5.6%). Điều này phản ánh sự tập trung của sinh viên trong hai học kỳ chính trong năm học. Học kỳ 3, vốn chủ yếu dành cho các lớp cải thiện, có số lượng sinh viên rất ít so với tổng thể.

Thuộc tính **namhoc** là dữ liệu số, thể hiện năm mà sinh viên theo học tại trường.

Biểu đồ phân bố namhoc: Phân bố sinh viên theo năm học trải dài từ 2013 đến 2022, trong đó các năm học gần đây chiếm tỷ lệ lớn hơn. Xu hướng này có thể phản ánh sự gia tăng số lượng sinh viên mới nhập học hoặc sự tập trung của dữ liệu vào các năm gần đây trong quá trình thu thập.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



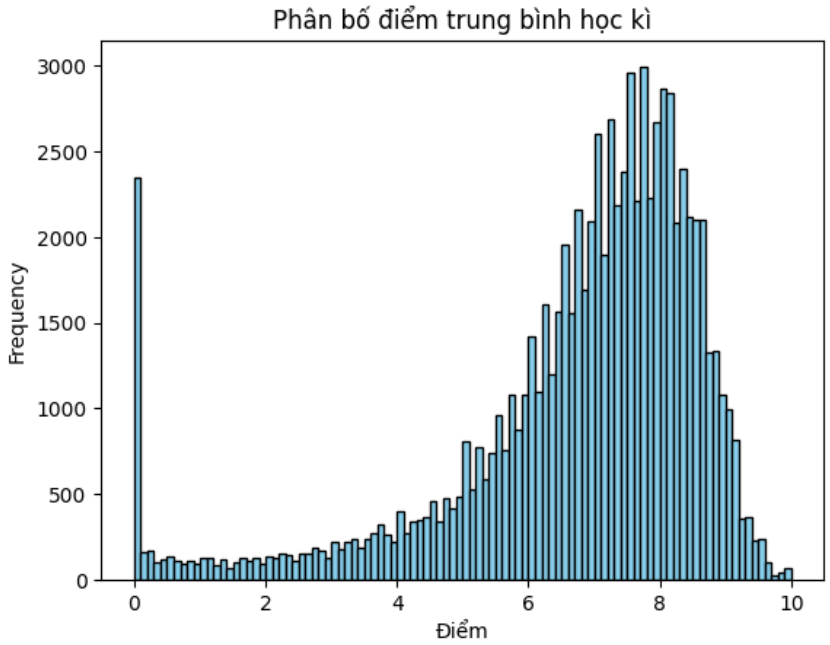
Hình 4: Biểu đồ phân bố năm học

Thuộc tính **dtbhk** là dữ liệu tỷ lệ, biểu diễn điểm trung bình của sinh viên trong một học kỳ cụ thể. Thông thường, điểm trung bình học kỳ trong hệ giáo dục ở Việt Nam có giá trị từ 0 đến 10, với các thang điểm phổ biến: Xuất sắc (≥9), Giỏi (≥8), Khá (≥6.5), Trung bình (≥5), và Yếu (<5).

Dữ liệu dtbhk có thể chứa giá trị 0, phản ánh sinh viên chưa có điểm học kỳ (do chưa đăng ký môn học, không làm khảo sát hoặc có vấn đề khác).

Việc phân tích thuộc tính dtbhk nhằm mục đích xác định tỷ lệ sinh viên ở các mức điểm trung bình khác nhau, đánh giá chất lượng học tập của sinh viên từ đó giúp phát hiện các trường hợp đặc biệt như sinh viên có thành tích xuất sắc hoặc khó khăn trong học tập

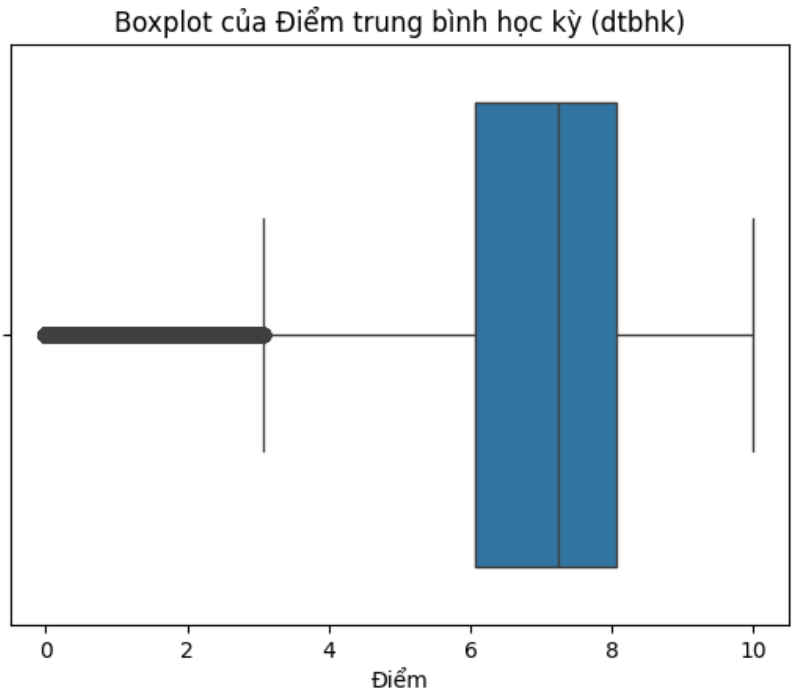
studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



Hình 5: Biểu đồ Histogram thể hiện tỷ lệ sinh viên ở các mức điểm trung bình học kỳ

Biểu đồ Histogram dtbhk: Biểu đồ này cho thấy đa phần sinh viên đạt điểm trung bình khá, với một số ít sinh viên gặp khó khăn hoặc có thành tích xuất sắc. Phân phối lệch phải cho thấy số lượng sinh viên có điểm cao giảm dần, phù hợp với kỳ vọng về phân bố điểm học tập trong trường. Tuy nhiên cũng có một bộ phận sinh viên có mức điểm là 0 hoặc gần 0, có thể các sinh viên này chưa có dữ liệu học tập hoặc đang có vấn đề trong việc học

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



Hình 6: Biểu đồ Boxplot thể hiện mức độ tập trung của điểm trung bình học kỳ

Để xác định độ tập trung của điểm trung bình học kì của sinh viên tập trung vào khoảng nào, cần sử ụng biểu đồ Boxplot.

Biểu đồ Boxplot cho thấy phần lớn sinh viên có điểm trung bình rơi vào mức trung bình khá (từ 6 đến 8 điểm), có một bộ phận sinh viên có điểm dưới 4, cho thấy phần lớn sinh viên có kết quả học tập khá tốt

3.2.1. Phân tích đa biến

Nhóm sử dụng phương pháp hồi quy tuyến tính để nhận xét mối quan hệ giữa điểm trung bình học kì và các biến độc lập khác như số tín chỉ học kì, năm học, học kỳ

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                  dtbhk   R-squared:                       0.060
Model:                            OLS   Adj. R-squared:                  0.060
Method:                 Least Squares   F-statistic:                     1098.
Date:                Wed, 21 May 2025   Prob (F-statistic):               0.00
Time:                        23:28:54   Log-Likelihood:            -1.4591e+05
No. Observations:               68603   AIC:                         2.918e+05
Df Residuals:                   68598   BIC:                         2.919e+05
Df Model:                           4
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       -256.1811      7.145    -35.855      0.000    -270.185    -242.177
namhoc         0.1300      0.004     36.783      0.000       0.123       0.137
sotchk         0.0665      0.001     44.427      0.000       0.064       0.069
hocky         -0.0189      0.014     -1.358      0.174      -0.046       0.008
 gioitinh     -0.7253      0.024    -30.503      0.000      -0.772      -0.679
==============================================================================
Omnibus:                    15081.908   Durbin-Watson:                   1.136
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            29859.819
Skew:                          -1.333   Prob(JB):                         0.00
Kurtosis:                       4.829   Cond. No.                     1.86e+06
==============================================================================
```

Hình 6: Kết quả phân tích hồi quy

Từ kết quả, ta thấy được giá trị P của 3 biến độc lập đều rất nhỏ, cho thấy độ ảnh hưởng lớn lên điểm trung bình học kì.

3.3. Nhận xét chất lượng bộ dữ liệu trước và sau khi xử lý

Để đánh giá chất lượng bộ dữ liệu, chúng ta sẽ xem xét tình trạng dữ liệu trước và sau quá trình tiền xử lý, tập trung vào các khía cạnh như kích thước, kiểu dữ liệu, giá trị thiếu và các giá trị ngoại lai/không hợp lệ.

3.3.1. Kích thước và cấu trúc:

- Dữ liệu có kích thước tương đối lớn, với 11379 bản ghi, cung cấp đủ thông tin để phân tích.
- Các cột bao gồm mssv (mã số sinh viên), namsinh (năm sinh), gioitinh (giới tính), 8 cột điểm trung bình học kỳ từ dtbhk_1 đến dtbhk_8, và dtb_toankhoa (điểm trung bình toàn khóa).

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

3.3.2. Kiểu dữ liệu

Kiểu dữ liệu của các cột được tóm tắt như sau:

Cột	Kiểu dữ liệu (Dtype)	Nhận xét
mssv	object	Phù hợp với dữ liệu định danh.
namsinh	int64	Cần kiểm tra giá trị.
gioitinh	int64	Cần kiểm tra giá trị.
dtbhk_1	float64	Phù hợp cho điểm số.
dtbhk_2	float64	Phù hợp cho điểm số.
dtbhk_3	float64	Phù hợp cho điểm số.
dtbhk_4	float64	Phù hợp cho điểm số.
dtbhk_5	float64	Phù hợp cho điểm số.
dtbhk_6	float64	Phù hợp cho điểm số.
dtbhk_7	float64	Phù hợp cho điểm số.
dtbhk_8	float64	Phù hợp cho điểm số.
dtb_toankhoa	float64	Phù hợp cho điểm số.

Bảng 8: Kiểu dữ liệu của các cột

3.3.3. Giá trị thiếu (NaN)

Đây là vấn đề nghiêm trọng nhất của bộ dữ liệu trước xử lý. Các cột mssv, namsinh, gioitinh, và dtb_toankhoa không có giá trị thiếu. Tuy nhiên, các cột điểm trung bình học kỳ có lượng lớn giá trị thiếu như sau:

Cột	Số lượng NaN	Tỷ lệ NaN (trên tổng số dòng)	Nhận xét
dtbhk_1	15	~0.13%	Rất ít
dtbhk_2	91	~0.80%	Thấp
dtbhk_3	398	~3.50%	Trung bình

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

dtbhk_4	2379	~20.91%	Đáng kể
dtbhk_5	2590	~22.76%	Đáng kể
dtbhk_6	4285	~37.66%	Cao
dtbhk_7	4477	~39.35%	Cao
dtbhk_8	6435	~56.55%	Rất cao, chiếm hơn một nửa tổng số dòng. Vấn đề lớn.

Bảng 9: Giá trị NaN

Số lượng giá trị thiếu tăng dần từ dtbhk_1 đến dtbhk_8, cho thấy dữ liệu càng về các học kỳ sau càng thiếu hụt nhiều, đặc biệt là dtbhk_8 với hơn một nửa số bản ghi bị thiếu. Điều này sẽ ảnh hưởng đáng kể đến khả năng phân tích và xây dựng mô hình nếu không được xử lý.

3.3.4. Dữ liệu bất thường (Outliers/Invalid Data)

Thống kê mô tả các cột số cho thấy sự hiện diện của các giá trị không hợp lệ:

Cột	min	25%	50%	75%	max	Nhận xét về bất thường
namsinh	0.00	0.00	1997.00	2000.00	2001.00	Giá trị min 0.00 và 25% là 0.00 cho thấy nhiều năm sinh không hợp lệ.
gioitinh	-1.00	-1.00	1.00	1.00	1.00	Giá trị min -1.00 là không hợp lệ cho giới tính (thường là 0/1).
dtbhk_X	1.00	(khác)	(khác)	(khác)	9.00/10.00	Các giá trị này nằm trong thang điểm 10, nhưng cần kiểm tra phân phối kỹ lưỡng để phát hiện các giá trị quá thấp hoặc quá cao bất thường.
dtb_toankhoa	0.44	6.70	7.41	08.03	9.58	Có vẻ hợp lý, nhưng giá trị 0.44 có thể là một outlier cần

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

						xem xét.

Bảng 10: Dữ liệu bất thường

3.3.5. Dữ liệu bất thường/Không hợp lệ

Các vấn đề về dữ liệu bất thường đã được xử lý hiệu quả:

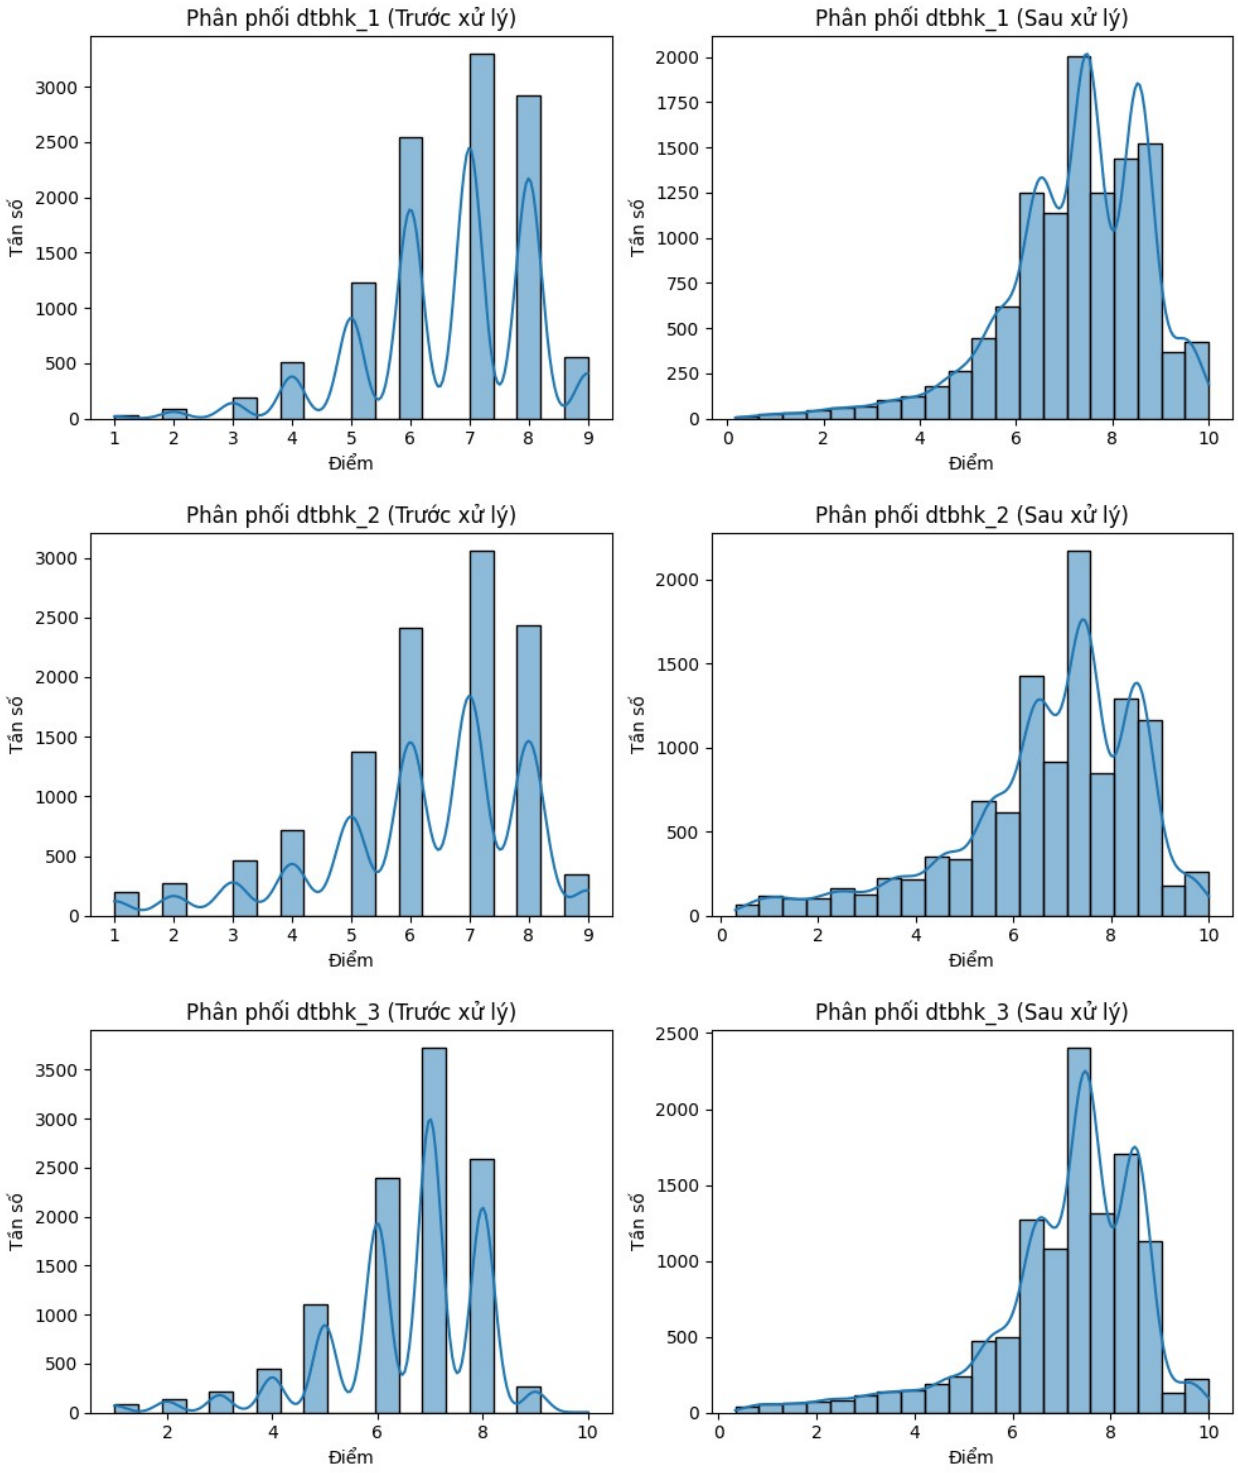
Cột	min	25%	50%	75%	max	Nhận xét về bất thường (Sau xử lý)
namsinh	1985.0	1997.0	1999.0	2000.0	2001.0	Đã được làm sạch, phản ánh các năm sinh hợp lệ.
gioitinh	0.0	1.0	1.0	1.0	1.0	Đã được chuẩn hóa thành 0 hoặc 1. Phân phối: Giới tính 1 (10368), Giới tính 0 (1011).
dtbhk_1	0.17	6.45	7.44	8.43	10.00	Các giá trị nằm trong thang điểm 10. Giá trị min 0.17 cần được xem xét nếu không hợp lý trong ngữ cảnh điểm số.
dtbhk_2	0.30	5.86	7.21	8.15	10.00	Tương tự dtbhk_1.
dtbhk_3	0.34	6.45	7.42	8.27	10.00	Tương tự dtbhk_1.
dtbhk_4	0.17	6.52	7.46	8.28	10.00	Tương tự dtbhk_1.
dtbhk_5	0.57	6.49	7.50	8.34	10.00	Tương tự dtbhk_1.
dtbhk_6	0.54	6.69	7.61	8.39	10.00	Tương tự dtbhk_1.
dtbhk_7	0.67	6.68	7.68	8.42	10.00	Tương tự dtbhk_1.
dtbhk_8	0.40	6.59	7.72	8.46	10.00	Tương tự dtbhk_1.

Bảng 11: Dữ liệu bất thường và không hợp lệ

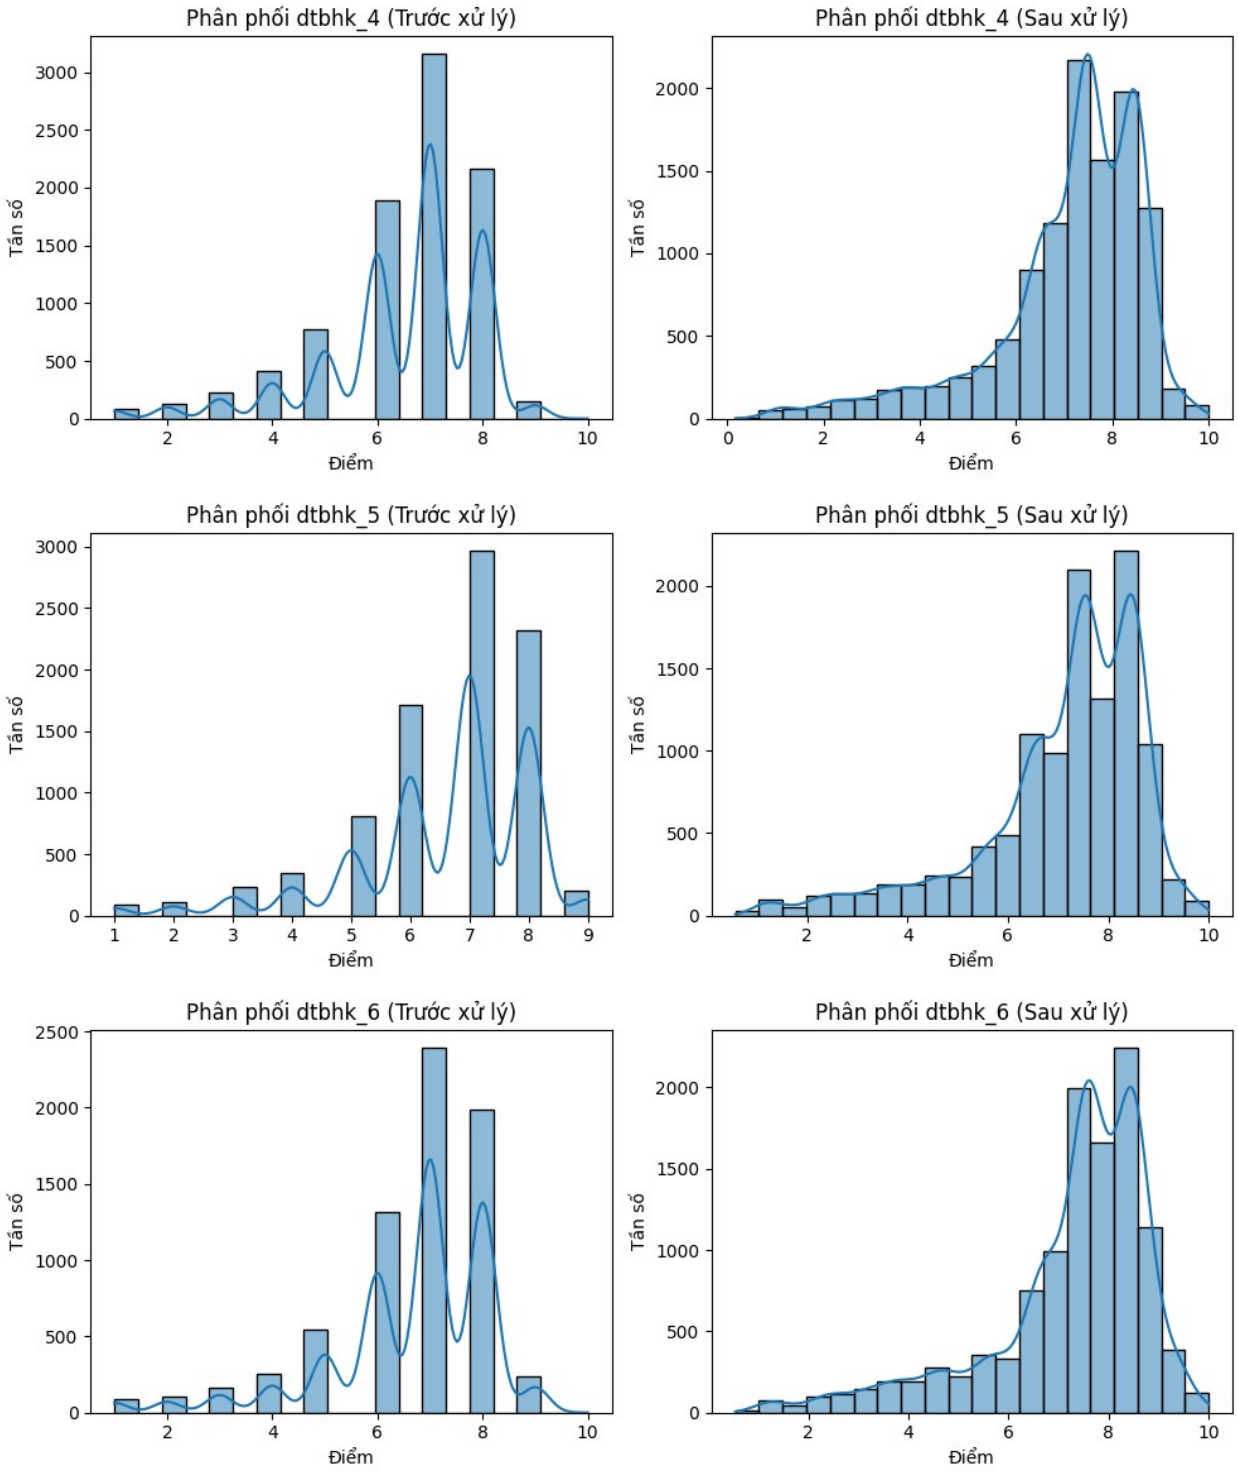
3.3.6. Phân phối các cột dtbhk trước và sau khi xử lý

Sau quá trình xử lý, bộ dữ liệu đã có những thay đổi đáng kể về phân phối của các cột điểm trung bình học kỳ, đồng thời giải quyết vấn đề giá trị thiếu.

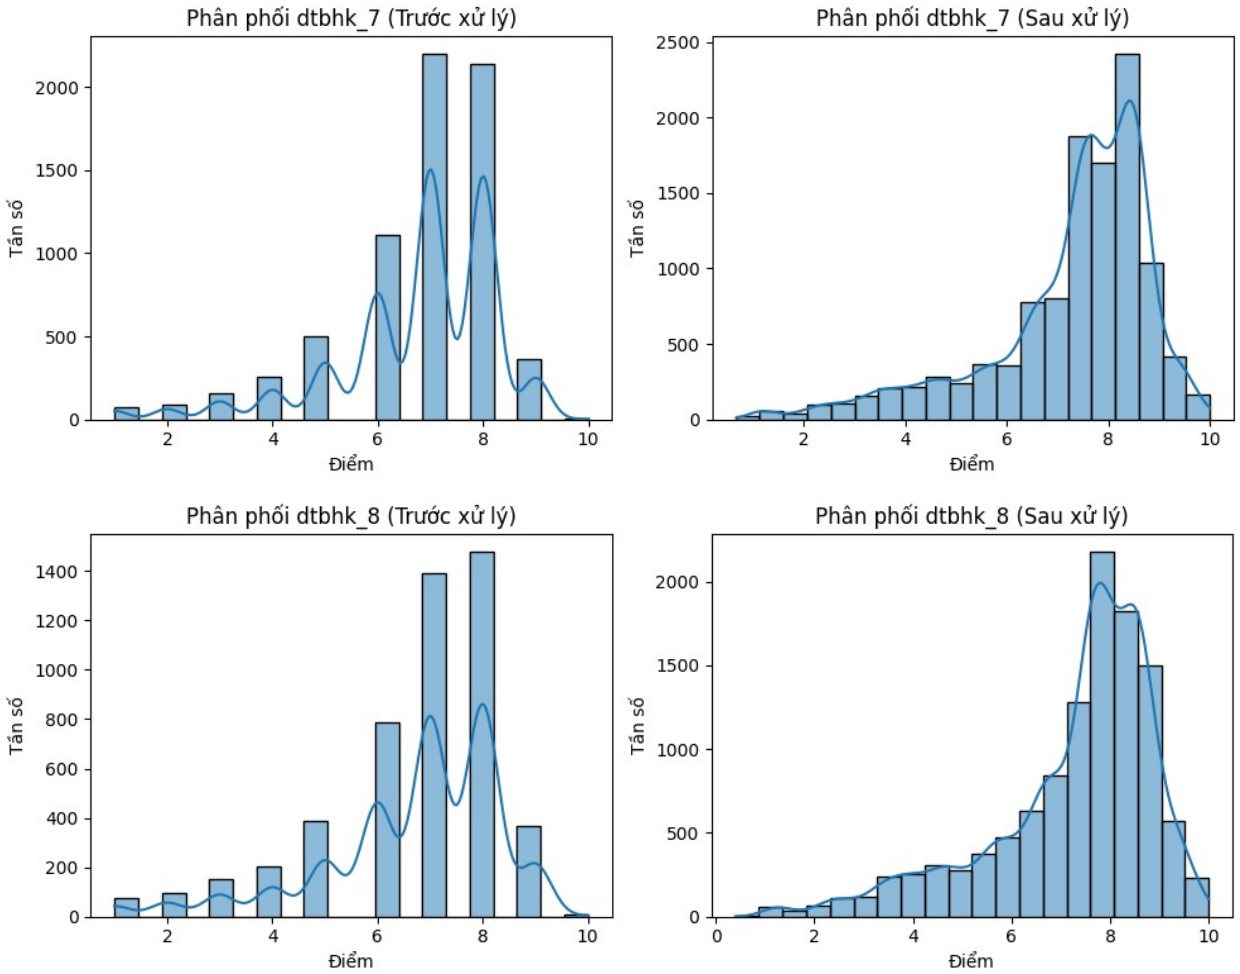
studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)



Hình 10: Phân phối điểm các học kỳ

Dưới đây là nhận xét chi tiết dựa trên các biểu đồ phân phối:

- **Loại bỏ giá trị thiếu:** Các biểu đồ phân phối sau xử lý cho thấy không còn bất kỳ "khoảng trống" nào tại các giá trị mà trước đó có thể bị ảnh hưởng bởi NaN. Điều này khẳng định rằng quá trình xử lý đã điền các giá trị thiếu một cách hiệu quả, tạo ra một phân phối liên tục hơn.
- **Thay đổi hình dạng phân phối:**
  - Ở các học kỳ đầu (dtbhk_1, dtbhk_2, dtbhk_3), phân phối trước xử lý có dạng "răng cưa" với các đỉnh rõ rệt tại các giá trị nguyên hoặc nửa nguyên. Sau xử lý, các phân phối này trở nên mượt mà hơn, cho thấy sự ảnh hưởng của phương pháp điền giá trị thiếu (có thể là điền bằng giá trị trung bình, trung vị hoặc một phương pháp phức tạp hơn).

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

  - Ở các học kỳ sau (dtbhk_4 đến dtbhk_8), sự khác biệt giữa phân phối trước và sau xử lý càng trở nên rõ rệt do số lượng giá trị thiếu ban đầu lớn. Phân phối sau xử lý thường có xu hướng tập trung hơn ở một số khoảng điểm nhất định, và hình dạng tổng thể có thể khác biệt đáng kể so với phân phối rời rạc ban đầu. Điều này là hệ quả của việc ước tính và điền các giá trị bị thiếu.
- **Sự xuất hiện của các giá trị biên:** Ở một số học kỳ (ví dụ: dtbhk_1), phân phối sau xử lý cho thấy sự xuất hiện của một lượng nhỏ các giá trị rất thấp (gần 0) hoặc rất cao (gần 10) mà có thể không rõ ràng trong phân phối trước xử lý do ảnh hưởng của giá trị thiếu. Cần đánh giá xem liệu những giá trị biên này có hợp lý hay không và có thể là kết quả của phương pháp điền giá trị thiếu.
- **Xu hướng chung:** Nhìn chung, sau khi xử lý giá trị thiếu, các phân phối điểm trung bình học kỳ có xu hướng trở nên đầy đủ và liên tục hơn, nhưng đồng thời cũng có thể bị ảnh hưởng bởi phương pháp điền giá trị thiếu, làm thay đổi hình dạng và đặc điểm phân phối ban đầu. Việc lựa chọn phương pháp điền giá trị thiếu phù hợp là rất quan trọng để tránh làm sai lệch thông tin của dữ liệu.

3.3.7. Tổng quan chất lượng bộ dữ liệu trước và sau khi xử lý

Tiêu chí	Trước	Sau	Nhận xét
Số lượng dòng	11379	11379	Giữ nguyên, không mất dữ liệu.
Số lượng cột	12	12	Giữ nguyên
Giá trị thiếu (NaN)	Rất nhiều (đặc biệt dtbhk_8 lên tới 6435 - 56.55%)	0 ở tất cả các cột.	Cải thiện đáng kể, dữ liệu sẵn sàng hơn.
namsinh	Có giá trị 0.00 (min, 25%)	Đã được làm sạch, min là 1985.0.	Dữ liệu năm sinh đã hợp lệ.
gioitinh	Có giá trị -1.00 (min, 25%)	Đã được làm sạch, min là 0.0, max là 1.0.	Dữ liệu giới tính đã hợp lệ.
Phân phối dtbhk_X	Có "lỗ hổng" do NaN, phân bố có thể "răng cưa".	Mượt mà hơn, không còn NaN, phân bố có thể dịch chuyển nhẹ.	Tốt hơn cho phân tích, nhưng cần kiểm tra min của điểm.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Mức độ sẵn sàng cho mô hình	Rất thấp, cần xử lý nhiều.	Rất cao, sẵn sàng cho các bước tiếp theo.	Đã có sự chuẩn bị tốt.

Bảng 12: Tổng quan chất lượng bộ dữ liệu

3.4. Phương pháp tổ chức dữ liệu thực nghiệm

3.4.1. Phân chia dữ liệu theo học kỳ

Dữ liệu được thu thập và phân tích bao gồm điểm trung bình học kỳ (dtbhk) của sinh viên qua các học kỳ. Để phục vụ cho việc phân tích chuyên sâu hơn và xây dựng mô hình dự đoán, chúng tôi sẽ phân chia dữ liệu dựa trên các học kỳ cụ thể.

Cụ thể, dữ liệu có các cột dtbhk_1 đến dtbhk_8, tương ứng với điểm trung bình của từng học kỳ từ học kỳ 1 đến học kỳ 8. Việc phân chia này cho phép chúng ta:

- **Đánh giá xu hướng học tập:** Quan sát sự thay đổi trong điểm số của sinh viên qua từng học kỳ, từ đó nhận diện các giai đoạn mà sinh viên có thể gặp khó khăn hoặc có sự tiến bộ rõ rệt.
- **Xây dựng mô hình dự đoán theo giai đoạn:** Cho phép xây dựng các mô hình dự đoán điểm số hoặc nguy cơ bỏ học/chậm tốt nghiệp dựa trên dữ liệu của các học kỳ trước đó. Ví dụ, chúng ta có thể dự đoán điểm học kỳ 5 dựa trên điểm của học kỳ 1 đến 4.
- **Phân tích ảnh hưởng của từng học kỳ:** Xác định xem học kỳ nào có tác động lớn nhất đến kết quả học tập tổng thể hoặc đến khả năng hoàn thành chương trình của sinh viên.

Trong quá trình phân tích, chúng tôi sẽ xem xét việc tạo các tập con dữ liệu cho từng học kỳ hoặc kết hợp các học kỳ để tạo ra các biến mới phản ánh hiệu suất học tập tích lũy.

3.4.2. Xử lý các giá trị thiếu và không hợp lệ

Dữ liệu thực tế thường chứa các giá trị thiếu (missing values) và không hợp lệ (invalid values), có thể gây sai lệch kết quả phân tích nếu không được xử lý đúng cách.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Dựa trên phân tích EDA (Exploratory Data Analysis), chúng tôi đã tiến hành các bước sau để xử lý vấn đề này:

a. Phát hiện giá trị thiếu: Chúng tôi đã kiểm tra sự tồn tại của các giá trị thiếu trong tập dữ liệu. Các giá trị thiếu này thường được biểu thị bằng NaN (Not a Number) hoặc các ký hiệu khác. Việc xác định số lượng và vị trí của các giá trị thiếu là bước đầu tiên để đưa ra chiến lược xử lý phù hợp.

b. Phương pháp xử lý giá trị thiếu: Trong trường hợp này, chúng tôi đã áp dụng phương pháp thay thế giá trị thiếu bằng giá trị trung bình (mean) của cột tương ứng.

- **Ưu điểm của phương pháp này:**
  - Đơn giản và dễ thực hiện.
  - Giữ lại được số lượng bản ghi tối đa, tránh làm mất thông tin.
  - Giúp duy trì phân phối của dữ liệu nếu các giá trị thiếu được phân bố ngẫu nhiên và số lượng không quá lớn.
- **Cơ sở lựa chọn:**
  - Điểm trung bình (mean) là một thước đo thống kê phổ biến, ít bị ảnh hưởng bởi các giá trị ngoại lệ nếu dữ liệu có phân phối tương đối đối xứng.
  - Trong bối cảnh điểm số, việc thay thế bằng điểm trung bình học kỳ sẽ giúp duy trì tính hợp lý của dữ liệu, giả định rằng một sinh viên vắng mặt hoặc không có điểm ở một học kỳ cụ thể có thể có điểm số gần với mức trung bình của nhóm.
  - Cụ thể, lệnh **df['dtbhk_x'].fillna(df['dtbhk_x'].mean(), inplace=True)** đã được sử dụng cho từng cột điểm trung bình học kỳ để thực hiện việc này.

c. Xử lý giá trị không hợp lệ: Ngoài các giá trị thiếu, chúng tôi cũng đã xem xét các giá trị không hợp lệ, chẳng hạn như điểm số nằm ngoài phạm vi cho phép (ví dụ: điểm nhỏ hơn 0 hoặc lớn hơn 10).

- **Phát hiện:** Dựa trên các phân tích thống kê cơ bản (.describe()) và biểu đồ phân bố, chúng tôi đã kiểm tra các giá trị min và max của từng cột điểm trung bình học kỳ.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- **Giải pháp:** Nếu có bất kỳ giá trị nào nằm ngoài khoảng [0,10] (phạm vi điểm hợp lệ), chúng tôi sẽ cân nhắc các phương pháp xử lý như:
    - Thay thế bằng giá trị cận trên hoặc cận dưới (ví dụ: nếu >10 thì thay bằng 10, nếu <0 thì thay bằng 0).
    - Loại bỏ các bản ghi chứa giá trị không hợp lệ (nếu số lượng ít).
    - Điều tra nguyên nhân gốc rễ của các giá trị không hợp lệ để đưa ra giải pháp phù hợp nhất.
    - *Lưu ý:* Dựa trên thông tin cung cấp trong file Jupyter Notebook, các giá trị min và max cho các cột dtbhk_ đều nằm trong phạm vi [0,10] (ví dụ: min: 0.67, max: 10.0 cho dtbhk_7; min: 0.4, max: 10.0 cho dtbhk_8), cho thấy không có giá trị nào vượt ra ngoài khoảng điểm chuẩn. Do đó, không cần xử lý thêm cho các giá trị nằm ngoài phạm vi hợp lệ trong trường hợp này.

Kết luận:

Việc tách điểm trung bình theo học kỳ và xử lý các giá trị thiếu/không hợp lệ là những bước cơ bản nhưng thiết yếu trong quá trình chuẩn bị dữ liệu. Điều này đảm bảo rằng dữ liệu được sử dụng cho các phân tích tiếp theo là sạch, chính xác và đáng tin cậy, từ đó giúp đưa ra những hiểu biết sâu sắc và quyết định đúng đắn về hiệu suất học tập của sinh viên.

3.4.3. Chia dữ liệu train, test

Với từng bộ dữ liệu được phân chia theo học kỳ, nhóm tiếp tục thực hiện chia dữ liệu theo tỉ lệ **8:2**, tương ứng với tập huấn luyện (train) và tập kiểm tra (test). Quá trình chia dữ liệu được thực hiện ngẫu nhiên nhưng đảm bảo giữ nguyên phân phối của các nhãn, nhằm đảm bảo tính đại diện và công bằng cho các tập dữ liệu.

- **Tập huấn luyện (train)**: Dữ liệu này được sử dụng để huấn luyện mô hình, giúp mô hình học được các mối quan hệ giữa đầu vào và đầu ra.
- **Tập kiểm tra (test)**: Đây là tập dữ liệu hoàn toàn độc lập, được sử dụng để đánh giá hiệu quả cuối cùng của mô hình sau khi đã huấn luyện và tinh chỉnh.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Ngoài ra, để đánh giá hiệu quả của mô hình trên tập huấn luyện một cách toàn diện, nhóm tiếp tục áp dụng phương pháp Cross-Validation (CV) với 5 folds như sau:

- **5 folds**: Dữ liệu được chia thành 5 phần đều nhau, lần lượt sử dụng một phần để kiểm tra và các phần còn lại để huấn luyện.

3.4.4. Mục tiêu tổ chức

Mục tiêu chính của báo cáo này là sử dụng phân tích dữ liệu để đưa ra những hiểu biết sâu sắc về quá trình học tập của sinh viên và hỗ trợ các quyết định liên quan đến quản lý và hỗ trợ sinh viên tại trường đại học. Cụ thể, các mục tiêu bao gồm:

- **Hiểu rõ hiệu suất học tập của sinh viên:** Phân tích điểm trung bình học kỳ của sinh viên để đánh giá hiệu suất học tập tổng thể và xác định các yếu tố có thể ảnh hưởng đến kết quả học tập.
- **Xác định các xu hướng và mô hình học tập:** Phát hiện các xu hướng chung trong điểm số của sinh viên qua các học kỳ, bao gồm cả các giai đoạn tăng trưởng hoặc suy giảm hiệu suất.
- **Xây dựng nền tảng cho mô hình dự đoán:** Chuẩn bị dữ liệu và thực hiện các phân tích ban đầu để làm cơ sở cho việc phát triển các mô hình học máy nhằm dự đoán kết quả học tập trong tương lai của sinh viên.

CHƯƠNG 4. PHƯƠNG PHÁP ĐỀ XUẤT

4.1. Mô hình

4.1.1. Linear Regression

Linear Regression - Hồi quy tuyến tính là một phương pháp thống kê để hồi quy dữ liệu với biến phụ thuộc có giá trị liên tục trong khi các biến độc lập có thể có một trong hai giá trị liên tục hoặc là giá trị phân loại. Nói cách khác "Hồi quy tuyến tính" là một phương pháp để dự đoán biến phụ thuộc (Y) dựa trên giá trị của biến độc lập (X). Nó có thể được sử dụng cho các trường hợp dự đoán một số lượng liên tục. Ví dụ, dự đoán giao thông ở một cửa hàng bán lẻ, dự đoán thời gian người dùng dừng lại một trang nào

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

đó v.v... do đó thuật toán Linear Regression được dùng trong thực nhiệm cho bài toán này để dự đoán điểm trung bình học kỳ sinh viên dựa trên dữ liệu học tập quá khứ.

Linear Regression là một trong những phương pháp đơn giản và phổ biến nhất trong machine learning và thường được sử dụng để dự đoán giá trị của biến phụ thuộc dựa trên các biến độc lập.

Ưu điểm:

- *Đơn giản và dễ hiểu:* Linear regression là một thuật toán đơn giản và dễ hiểu. Công thức toán học của nó rất đơn giản và có thể giải thích một cách trực quan.
- *Tính linh hoạt:* Linear regression có thể được áp dụng cho cả các bài toán dự đoán đơn biến và đa biến. Nó cũng có thể mở rộng để xử lý các trường hợp phức tạp hơn thông qua việc sử dụng các biến độc lập tương tác và biến độc lập bậc cao (polynomial regression).
- *Tính tường minh và giải thích được:* Kết quả của linear regression có thể được giải thích một cách rõ ràng. Các hệ số hồi quy có thể biểu thị độ ảnh hưởng của từng biến độc lập đến biến phụ thuộc.
- *Tốc độ huấn luyện nhanh:* Với một tập dữ liệu nhỏ hoặc có số lượng biến độc lập ít, quá trình huấn luyện linear regression có thể diễn ra nhanh chóng.

Nhược điểm:

- *Giả định về mối quan hệ tuyến tính:* Linear regression giả định rằng mối quan hệ giữa biến phụ thuộc và biến độc lập là tuyến tính. Điều này có nghĩa là nếu mối quan hệ thực tế không phải là tuyến tính, linear regression có thể cho ra kết quả không chính xác hoặc không tốt.
- *Nhạy cảm với nhiễu:* Linear regression có thể bị ảnh hưởng bởi các điểm dữ liệu nhiễu. Các điểm dữ liệu nhiễu có thể ảnh hưởng đáng kể đến đường thẳng (hoặc siêu phẳng) tìm được, làm cho mô hình dự đoán kém chính xác.
- *Không thể mô hình hóa mối quan hệ phi tuyến:* Linear regression không thể mô hình hóa mối quan hệ phi tuyến giữa biến phụ thuộc và biến độc lập một cách

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

chính xác. Để xử lý mối quan hệ phi tuyến, cần phải sử dụng các phương pháp khác như polynomial regression hoặc các phương pháp hồi quy phi tuyến khác.

- *Dễ bị ảnh hưởng bởi đa cộng tuyến*: Khi có sự tương quan cao giữa các biến độc lập, linear regression có thể bị ảnh hưởng bởi hiện tượng đa cộng tuyến, gây khó khăn trong việc xác định độ ảnh hưởng riêng lẻ của từng biến độc lập.

4.1.2. XGBoost

XGBoost (Extreme Gradient Boosting) là một thuật toán học máy tập trung vào việc xây dựng một tập hợp các cây quyết định (decision trees) theo cách tối ưu hóa một hàm mất mát (loss function). Nó sử dụng kỹ thuật gradient boosting để khai thác lợi ích của các cây quyết định tập hợp và tối ưu hóa mô hình dự đoán.Là một giải thuật được dựa trện trên gradient boosting, tuy nhiên kèm theo đó là những cải tiến to lớn về mặt tối ưu thuật toán, về sự kết hợp hoàn hảo giữa sức mạnh phần mềm và phần cứng, giúp đạt được những kết quả vượt trội cả về thời gian training cũng như bộ nhớ sử dụng.XGBoost có khả năng xử lý cả bài toán phân loại và dự đoán

Mã nguồn mở với ~350 contributors và ~3,600 commits trên Gihub, XGBoost cho thấy những khả năng ứng dụng đáng kinh ngạc của mình như:

- XGBoost có thể được sử dụng để giải quyết được tất cả các vấn đề từ hồi quy (regression), phân loại (classification), ranking và giải quyết các vấn đề do người dùng tự định nghĩa.
- XGBoost hỗ trợ trên Windows, Linux và OS X.
- Hỗ trợ tất cả các ngôn ngữ lập trình chính bao gồm C ++, Python, R, Java, Scala và Julia.
- Hỗ trợ các cụm AWS, Azure và Yarn và hoạt động tốt với Flink, Spark và các hệ sinh thái khác.

Ưu điểm:

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- *Hiệu suất dự đoán cao:* XGBoost thường có hiệu suất dự đoán tốt hơn so với nhiều thuật toán học máy khác. Nó có khả năng tạo ra mô hình mạnh mẽ và ổn định, đặc biệt là khi áp dụng cho dữ liệu có kích thước lớn.
- *Xử lý tốt các biến độc lập*: XGBoost có khả năng xử lý các biến độc lập có loại dữ liệu đa dạng, bao gồm cả dữ liệu số và dữ liệu hạng mục. Nó cũng xử lý tốt sự tương tác giữa các biến độc lập, giúp mô hình dự đoán chính xác hơn.
- *Hạn chế quá khớp:* XGBoost có khả năng giảm quá khớp (overfitting) thông qua việc sử dụng các kỹ thuật chặn (regularization) và cắt tỉa (pruning) cây quyết định.
- *Xử lý nhanh và tối ưu:* XGBoost được tối ưu hóa để đạt hiệu suất tính toán cao. Nó sử dụng các kỹ thuật như gradient boosting, việc song song hóa và sử dụng cây quyết định dựa trên cây histogram để tăng tốc độ huấn luyện và dự đoán.

Nhược điểm:

- *Đòi hỏi hiểu biết về siêu tham số:* XGBoost có nhiều siêu tham số cần được điều chỉnh để đạt hiệu suất tốt nhất. Điều này đòi hỏi người dùng có hiểu biết về thuật toán và kỹ năng điều chỉnh siêu tham số phù hợp.
- *Đòi hỏi tài nguyên tính toán:* XGBoost có thể yêu cầu nhiều tài nguyên tính toán, đặc biệt là khi xử lý dữ liệu lớn và sử dụng nhiều cây quyết định.

4.1.3. Random Forest

Ensemble Learning, tức là kết hợp nhiều mô hình học máy đơn lẻ để tạo ra một dự đoán cuối cùng. Nó được sử dụng cho cả bài toán phân loại và dự đoán.

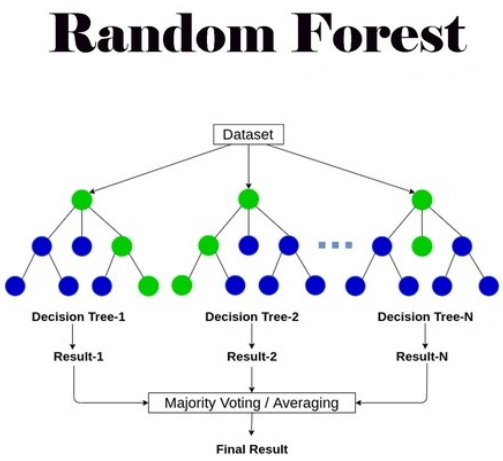
Random Forest gồm nhiều cây quyết định, mỗi cây quyết định đều có những yếu tố ngẫu nhiên, nó là Ensemble Learning, tức là kết hợp nhiều mô hình học máy đơn lẻ để tạo ra một dự đoán cuối cùng, được sử dụng cho cả bài toán phân loại và dự đoán :

1. Lấy ngẫu nhiên dữ liệu để xây dựng cây quyết định.
2. Lấy ngẫu nhiên các thuộc tính để xây dựng cây quyết định.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Do mỗi cây quyết định trong thuật toán Random Forest không dùng tất cả dữ liệu training, cũng như không dùng tất cả các thuộc tính của dữ liệu để xây dựng cây nên mỗi cây có thể sẽ dự đoán không tốt, khi đó mỗi mô hình cây quyết định không bị overfitting mà có thể bị underfitting, hay nói cách khác là mô hình có high bias. Tuy nhiên, kết quả cuối cùng của thuật toán Random Forest lại tổng hợp từ nhiều cây quyết định, thế nên thông tin từ các cây sẽ bổ sung thông tin cho nhau, dẫn đến mô hình có kết quả dự đoán tốt.

Ý tưởng tổng hợp các cây quyết định của thuật toán Random Forest giống với ý tưởng của The Wisdom of Crowds được đề xuất bởi by James Surowiecki vào năm 2004. The Wisdom of Crowds nói rằng thông thường tổng hợp thông tin từ 1 nhóm sẽ tốt hơn từ một cá nhân. Ở thuật toán Random Forest cũng tổng hợp thông tin từ 1 nhóm các cây quyết định và kết quả cho ra tốt hơn thuật toán Decision Tree với 1 cây quyết định.



Hình 11: Random Forest

Ưu điểm:

- *Hiệu suất dự đoán cao:* Random Forest thường có hiệu suất dự đoán tốt hơn so với các thuật toán học máy đơn lẻ, như cây quyết định. Điều này đặc biệt đúng khi tập dữ liệu lớn và phức tạp.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- *Khả năng xử lý đa chiều và không gian biến động cao*: Random Forest có khả năng xử lý các bài toán có nhiều biến độc lập và không gian biến động cao. Nó có thể xử lý cả dữ liệu số và dữ liệu hạng mục.
- *Hạn chế ảnh hưởng của nhiễu và quá khớp*: Random Forest có khả năng ổn định hơn so với các mô hình học máy đơn lẻ khi đối mặt với nhiễu và có khả năng giảm quá khớp (overfitting).
- *Dễ dàng ước lượng độ quan trọng của biến:* Random Forest cung cấp thông tin về độ quan trọng của các biến độc lập trong quá trình dự đoán. Điều này giúp chúng tôi hiểu rõ hơn về tầm quan trọng của từng biến đối với kết quả dự đoán.

Nhược điểm:

- *Khó diễn giải:* Khi Random Forest sử dụng một số lượng lớn cây quyết định, việc diễn giải kết quả trở nên khó khăn do sự phức tạp và tương tác giữa các cây.
- *Tốn thời gian và tài nguyên tính toán:* Random Forest có thể tốn nhiều thời gian và tài nguyên tính toán khi huấn luyện và dự đoán, đặc biệt là khi số lượng cây và kích thước tập dữ liệu lớn.
- *Cần điều chỉnh siêu tham số:* Random Forest có một số siêu tham số cần được điều chỉnh, như số lượng cây, độ sâu cây, số lượng biến đặc trưng được chọn ngẫu nhiên cho mỗi cây. Việc điều chỉnh siêu tham số phù hợp là quan trọng để đạt hiệu suất tốt nhất từ thuật toán.

4.2. Kiến trúc hệ thống

4.2.1. Công nghệ sử dụng

a) Spark Mllib

Spark Mllib là thư viện học máy của Spark được tạo ra với mục tiêu có thể giải quyết các bài toán ML một cách dễ dàng hơn. Mặc dùng các thư viện mà MLlib mang lại không phong phú bằng python với những sklearn, tensorflow… Tuy nhiên MLlib hỗ trợ cho chương trình có thể chạy phân tán trên nhiều máy tại cụm Spark được thiết lập trước đó và có khả năng tích hợp tốt với Hadoop Distributed File System (HDFS).

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Đối với đề tài này, nhóm sử dụng Spark Mllib để tạo các model học máy như Linear Regressiom, Random Forest nhằm phục vụ quá trình training trên bộ dữ liệu điểm trung bình, cũng như cung cấp cho người dùng cuối đa dạng các model dự đoán.

b) Hadoop Distributed File System

HDFS (Hadoop Distributed File System) là một hệ thống lưu trữ dữ liệu được Hadoop sử dụng. HDFS hoạt động như một hệ thống tệp phân tán được thiết kế để chạy trên các thiết bị phần cứng thông thường.

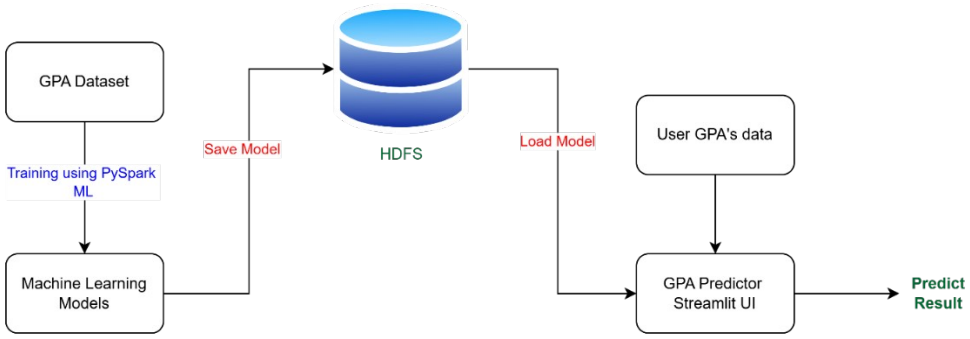
Đối với đề tài này, nhóm sử dụng HDFS như là kho lưu trữ dữ liệu và model chính, các model sau khi được train sẽ được lưu trên HDFS, người dùng cuối có thể chọn model mong muốn và model tương ứng sẽ được load để thực hiện dự đoán trên dữ liệu điểm của người dùng

c) Streamlit

Streamlit là 1 framework rất phổ biến trong cộng đồng khoa học dữ liệu và máy học vì nó cho phép tạo ra các giao diện người dùng tương tác mà không cần kỹ năng phát triển web chuyên sâu.

Đối với đề tài này, nhóm sử dụng streamlit đề xây dựng giao diện tương tác cho người dùng cuối, giao diện sẽ có các select và form cho người dùng chọn model và nhập dữ liệu để tiến hành dự đoán

4.2.2. Kiến trúc



Hình 12: Kiến trúc hệ thống

Dataset sau khi qua các bước xử lí sẽ được train bằng các model Machine Learning: Linear Regression, Random Forest, XGboost. Model sau khi train xong sẽ được lưu bằng

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

HDFS. Khi người dùng chọn 1 model để dự đoán thì sẽ load model tương ứng và dự đoán trên dữ liệu được người dùng cung cấp

CHƯƠNG 5. THỰC NGHIỆM

5.1. Độ đo đánh giá

5.1.1. Giới thiệu

Báo cáo này trình bày các độ đo đánh giá được sử dụng để phân tích hiệu suất của các mô hình học máy được phát triển nhằm mục đích dự đoán [điền vào đây: ví dụ: điểm số môn học, giá trị tài sản, v.v.]. Việc lựa chọn các độ đo đánh giá phù hợp là yếu tố then chốt để xác định mức độ chính xác, đáng tin cậy và khả năng tổng quát hóa của mô hình trên dữ liệu chưa từng thấy.

5.1.2. Các Độ đo Đánh giá Chính

Trong bài toán hồi quy, mục tiêu là dự đoán một giá trị liên tục. Do đó, các độ đo đánh giá tập trung vào việc định lượng sự khác biệt giữa giá trị dự đoán và giá trị thực tế. Các độ đo chính được sử dụng trong nghiên cứu này bao gồm:

- **Sai số tuyệt đối trung bình (Mean Absolute Error - MAE)**
    - **Định nghĩa:** MAE là giá trị trung bình của các sai số tuyệt đối giữa giá trị thực tế (y_i) và giá trị dự đoán (haty_i).
    - **Công thức:** $\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}\left|y_i - \hat{y}_i\right|$
    - **Trong đó:**
        - n: Số lượng mẫu dữ liệu
        - y_i: Giá trị thực tế của mẫu thứ i
        - haty_i: Giá trị dự đoán của mô hình cho mẫu thứ i
    - **Ý nghĩa:** MAE cung cấp một thước đo trực tiếp về độ lớn trung bình của lỗi mà không xét đến hướng của lỗi. Nó có cùng đơn vị với biến mục tiêu,

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

giúp dễ dàng diễn giải. Giá trị MAE thấp hơn cho thấy mô hình dự đoán chính xác hơn.

- **Ưu điểm:** Dễ hiểu, ít bị ảnh hưởng bởi các giá trị ngoại lệ hơn các độ đo dựa trên bình phương sai số.
- **Nhược điểm:** Không trừng phạt mạnh các lỗi lớn.

- **Sai số bình phương trung bình (Mean Squared Error - MSE)**
  - **Định nghĩa:** MSE là giá trị trung bình của các bình phương của sai số giữa giá trị thực tế (y_i) và giá trị dự đoán (haty_i).
  - **Công thức:** MSE = $\frac{1}{n}\sum_{i=1}^{n}\left(y_i-\hat{y}_i\right)^2$
  - **Ý nghĩa:** Bằng cách bình phương sai số, MSE đặt trọng số lớn hơn vào các lỗi lớn hơn. Điều này làm cho nó nhạy cảm hơn với các giá trị ngoại lệ so với MAE. Giá trị MSE thấp hơn cho thấy hiệu suất mô hình tốt hơn. Đơn vị của MSE là bình phương của đơn vị biến mục tiêu.
  - **Ưu điểm:** Trừng phạt các lỗi lớn mạnh hơn, có tính vi phân (dễ dàng tối ưu trong các thuật toán học máy).
  - **Nhược điểm:** Đơn vị không giống với biến mục tiêu, có thể khó diễn giải trực tiếp. Rất nhạy cảm với các giá trị ngoại lệ.
- **Căn bậc hai của sai số bình phương trung bình (Root Mean Squared Error - RMSE)**
  - **Định nghĩa:** RMSE là căn bậc hai của MSE.
  - **Công thức:** RMSE=$\sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i-\hat{y}_i\right)^2}$
  - **Ý nghĩa:** RMSE đưa độ đo về cùng đơn vị với biến mục tiêu, giúp việc diễn giải trở nên dễ dàng và trực quan hơn so với MSE. Giống như MSE, RMSE cũng nhạy cảm với các lỗi lớn. Giá trị RMSE thấp hơn chỉ ra một mô hình chính xác hơn.
  - **Ưu điểm:** Cùng đơn vị với biến mục tiêu, dễ diễn giải.
  - **Nhược điểm:** Vẫn nhạy cảm với các giá trị ngoại lệ.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- **Hệ số xác định (R-squared - R2)**
    - **Định nghĩa:** R2 là một độ đo thống kê cho biết mức độ phù hợp của mô hình hồi quy với dữ liệu thực tế. Nó biểu thị tỷ lệ phương sai của biến phụ thuộc được giải thích bởi các biến độc lập trong mô hình.
    - **Công thức:** $R2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \overline{y})^2}$
    - Trong đó:
    - bary: Giá trị trung bình của biến thực tế y
    - **Ý nghĩa:** Giá trị của R2 nằm trong khoảng từ 0 đến 1, với giá trị gần 1 cho thấy mô hình giải thích được phần lớn sự biến động của biến phụ thuộc. Một R2 cao thường chỉ ra một mô hình có khả năng dự đoán tốt. Tuy nhiên, R2 cũng có thể có giá trị âm nếu mô hình tệ hơn cả việc dự đoán giá trị trung bình.
    - **Ưu điểm:** Cung cấp một cái nhìn tổng thể về khả năng giải thích dữ liệu của mô hình.
    - **Nhược điểm:** Có thể tăng lên khi thêm các biến độc lập, ngay cả khi chúng không có ý nghĩa thống kê (có thể khắc phục bằng cách sử dụng R2 hiệu chỉnh - Adjusted R2 nếu có nhiều biến).

5.1.3. Lựa chọn Độ đo Đánh giá

Việc lựa chọn độ đo đánh giá phụ thuộc vào mục tiêu cụ thể của bài toán và tầm quan trọng của các loại sai số khác nhau.

- Nếu quan tâm đến độ lớn trung bình của sai số và muốn một độ đo dễ hiểu, **MAE** là một lựa chọn tốt.
- Nếu muốn trừng phạt các sai số lớn hơn một cách nghiêm khắc, **MSE** hoặc **RMSE** sẽ phù hợp hơn. RMSE thường được ưa chuộng hơn MSE vì nó có cùng đơn vị với biến mục tiêu.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

- **R2** cung cấp một cái nhìn tổng thể về khả năng giải thích dữ liệu của mô hình, giúp hiểu được mức độ "phù hợp" của mô hình với dữ liệu.

5.2. Thông số chi tiết các thuật toán

5.2.1. Linear Regression with Cross validation

Mô hình	Tham số	Giá trị
Linear Regression	featuresCol	"features"
	labelCol	"dtbhk_x"
	regParam	[0.01, 0.05, 0.1, 0.3, 0.5]
	elasticNetParam	[0, 0.3, 0.5, 0.7, 1.0]
	maxIter	[10, 50, 100]
	estimator	lr
	estimatorParamMaps	paramGrid
	evaluator	evaluator
	numFolds	5

Bảng 13 13: Tham số Linear Regression

5.2.2. Random Forest

Mô hình	Tham số	Giá trị
RandomForestRegressor	featuresCol	"features"
	labelCol	"dtbhk_x"
	numTrees	100
	maxDepth	5

Bảng 1414: Tham số Random Forest

5.2.3. XGboost

Mô hình	Tham số	Giá trị
XGboost	n_estimators	200
	learning_rate	0.1
	max_depth	3
	random_state	42

Bảng 1515: Tham số XGboost

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

5.3. Đánh giá thực nghiệm

5.3.1. Kết quả thực nghiệm

Model	RMSE	R2	MSE	MAE
Linear Regression CV (7 semesters)	1,0856	0,5942	1,1784	0,7555
Linear Regression CV (6 semesters)	1,0689	0,5918	1,1426	0,7205
Linear Regression CV (5 semesters)	1,0220	0,6226	1,0444	0,6982
Linear Regression CV (4 semesters)	1,0576	0,5864	1,1186	0,7288
Linear Regression CV (3 semesters)	1,0256	0,5969	1,0519	0,7141
Random Forest (7 semesters)	1,0676	0,6075	1,1397	0,7450
Random Forest (6 semesters)	1,0528	0,6040	1,1084	0,7090
Random Forest (5 semesters)	1,0169	0,6263	1,0340	0,6840
Random Forest (4 semesters)	1,0399	0,6001	1,0815	0,7223
Random Forest (3 semesters)	1,0209	0,6007	1,0421	0,7083
XGBoost (7 semesters)	1,0501	0,6199	1,1028	0,7003
XGBoost (6 semesters)	1,0526	0,6055	1,1081	0,7106
XGBoost (5 semesters)	0,9500	0,6639	0,9025	0,6456
XGBoost (4 semesters)	1,0041	0,6204	1,0083	0,6959
XGBoost (3 semesters)	1,0624	0,5853	1,1287	0,7264

Bảng 16 16: Kết quả thực nghiệm

5.3.2. Nhận xét

Bảng kết quả thực nghiệm so sánh hiệu suất của ba mô hình học máy (Linear Regression CV, Random Forest, và XGBoost) trên tập dữ liệu được huấn luyện với số lượng học kỳ khác nhau (7, 6, 5, 4, 3 học kỳ). Các chỉ số hiệu suất được đánh giá bao gồm RMSE, R2, MSE và MAE.

1. Đánh giá tổng quan hiệu suất của các mô hình:

- **XGBoost (5 semesters)** nổi bật là mô hình có hiệu suất tốt nhất trong số các cấu hình thử nghiệm, đạt RMSE thấp nhất (0,9500), MSE thấp nhất (0,9025) và R2 cao nhất (0,6639), cùng với MAE thấp thứ hai (0,6456). Điều này cho thấy XGBoost có khả năng dự đoán chính xác và giải thích được nhiều phương sai trong dữ liệu nhất khi sử dụng 5 học kỳ.
- **Linear Regression CV** và **Random Forest** thể hiện hiệu suất tương đối ổn định nhưng thường kém hơn XGBoost về các chỉ số lỗi (RMSE, MSE, MAE) và khả năng giải thích phương sai (R2).

2. Ảnh hưởng của số lượng học kỳ đến hiệu suất mô hình:

- **XGBoost:**
  - Hiệu suất tốt nhất của XGBoost đạt được ở **5 học kỳ**.
  - Với **3 học kỳ**, hiệu suất của XGBoost giảm đáng kể so với 5 học kỳ (RMSE tăng từ 0,9500 lên 1,0624, R2 giảm từ 0,6639 xuống 0,5853). Điều này cho

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

thấy việc giảm số lượng học kỳ xuống quá thấp có thể làm giảm khả năng học của mô hình.
    - Đối với 4, 6 và 7 học kỳ, hiệu suất của XGBoost cũng không tốt bằng 5 học kỳ, cho thấy 5 học kỳ có thể là điểm tối ưu cho tập dữ liệu và cấu hình này.
- **Linear Regression CV và Random Forest:**
    - Đối với cả hai mô hình này, hiệu suất thường tốt hơn một chút khi số lượng học kỳ giảm từ 7 xuống 5. Cụ thể, tại **5 học kỳ**, cả Linear Regression CV và Random Forest đều đạt được RMSE và MSE thấp hơn, cùng với R2 cao hơn so với các cấu hình 6 hoặc 7 học kỳ.
    - Tuy nhiên, khi giảm xuống **3 hoặc 4 học kỳ**, hiệu suất của chúng có xu hướng dao động hoặc kém hơn so với 5 học kỳ, đặc biệt là R2.
    - Nhìn chung, xu hướng cho thấy việc sử dụng một số lượng học kỳ "vừa phải" (ví dụ: 5 học kỳ) có thể mang lại hiệu suất tối ưu hơn là sử dụng quá nhiều hoặc quá ít học kỳ cho các mô hình này.

3. So sánh các mô hình theo từng số lượng học kỳ:

- **7 học kỳ:** XGBoost có R2 tốt hơn một chút (0, 6199) so với Linear Regression CV (0,5942) và Random Forest (0,6075). XGBoost cho thấy RMSE, MSE và MAE thấp hơn một chút so với hai mô hình còn lại, cho thấy hiệu suất nhỉnh hơn.
- **6 học kỳ:** Các mô hình có hiệu suất tương đương nhau, với XGBoost và Random Forest nhỉnh hơn Linear Regression CV một chút về R2.
- **5 học kỳ:** XGBoost vượt trội rõ rệt với RMSE, MSE và MAE thấp nhất, cùng với R2 cao nhất trong tất cả các thử nghiệm. Linear Regression CV và Random Forest cũng đạt hiệu suất tốt nhất của chính chúng ở cấu hình 5 học kỳ.
- **4 học kỳ:** XGBoost tiếp tục thể hiện hiệu suất tốt nhất, với RMSE thấp nhất (1,0041) và R2 cao nhất (0,6204).
- **3 học kỳ:** Các mô hình có hiệu suất tương đối giống nhau, với R2 thấp hơn so với các cấu hình học kỳ khác. XGBoost có R2 thấp nhất ở cấu hình này, trong khi Random Forest và Linear Regression CV có R2 tương tự nhau.

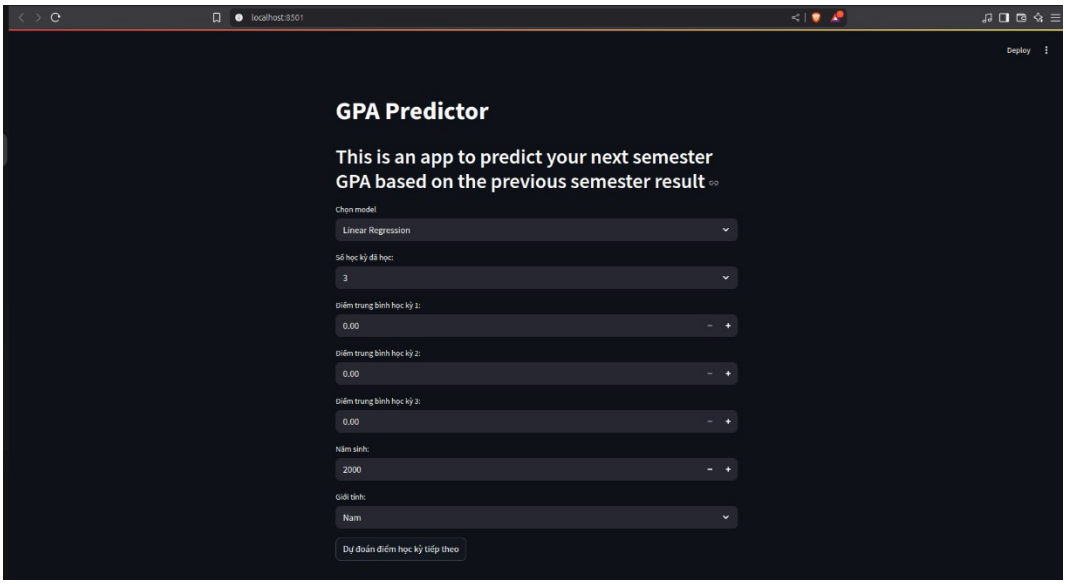
Kết luận:

Dựa trên các kết quả đã phân tích, mô hình **XGBoost với 5 học kỳ** là lựa chọn tốt nhất để dự đoán, mang lại sự cân bằng tối ưu giữa độ chính xác (RMSE, MAE thấp) và khả năng giải thích phương sai (R2 cao). Đối với các mô hình Linear Regression CV và Random Forest, việc giới hạn số lượng học kỳ ở mức 5 cũng cho thấy hiệu suất được cải thiện so với việc sử dụng nhiều học kỳ hơn. Điều này gợi ý rằng một lượng dữ liệu lịch sử vừa đủ (tương đương 5 học kỳ) có thể là tối ưu để các mô hình này học và đưa ra dự đoán hiệu quả.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

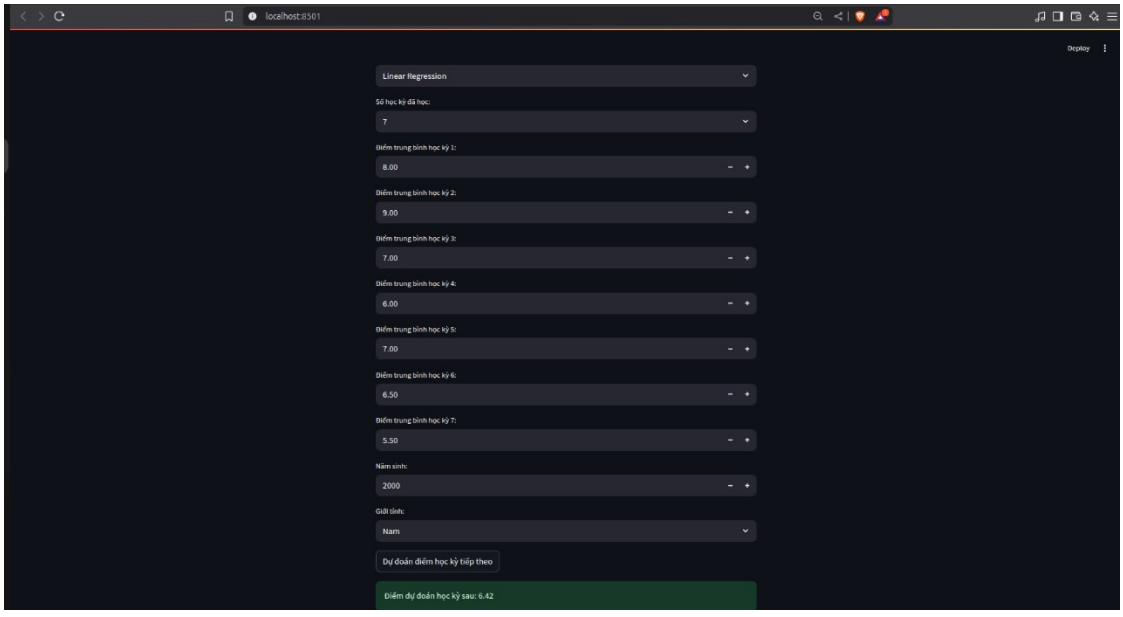
5.4. Ứng dụng thực nghiệm

Ứng dụng web GPAPredictor được xây dựng bằng framework Streamlit, cho phép người dùng cuối chọn số học kì đã học và model mong muốn, sau đó cho phép người dùng nhập thông tin điểm các kì đã học để dự đoán điểm kì tiếp theo. Model của ứng dụng được train bằng bộ dữ liệu điểm trung bình của sinh viên UIT



Hình 14: Giao diện chính của ứng dụng

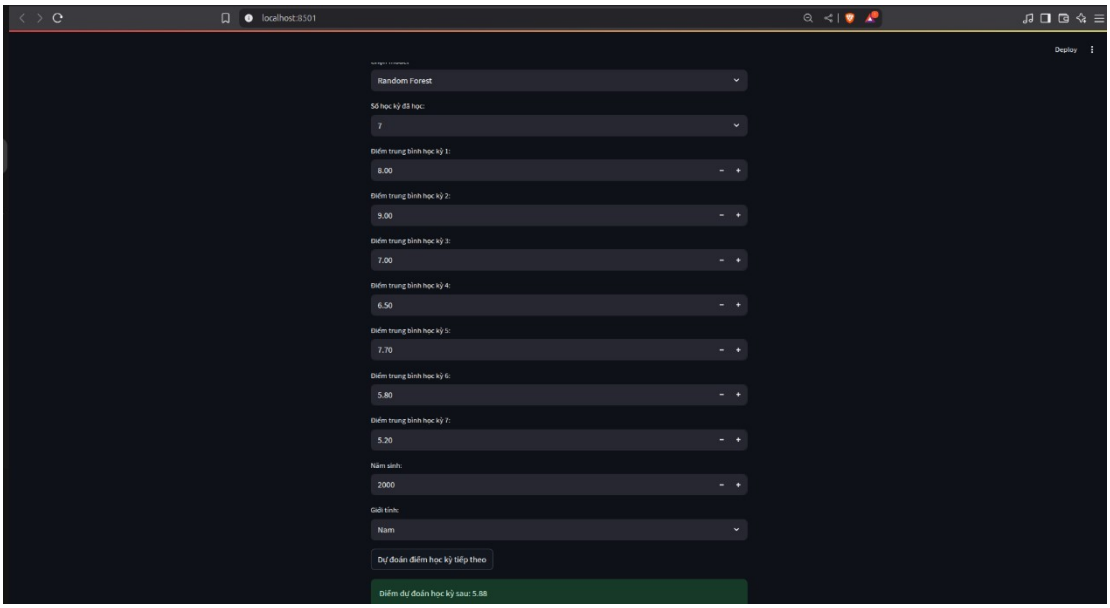
Dự đoán điểm kì thứ 8 bằng dữ liệu 7 kì trước, sử dụng thuật toán Linear Regression



Hình 15: Demo thuật toán Linear Regression

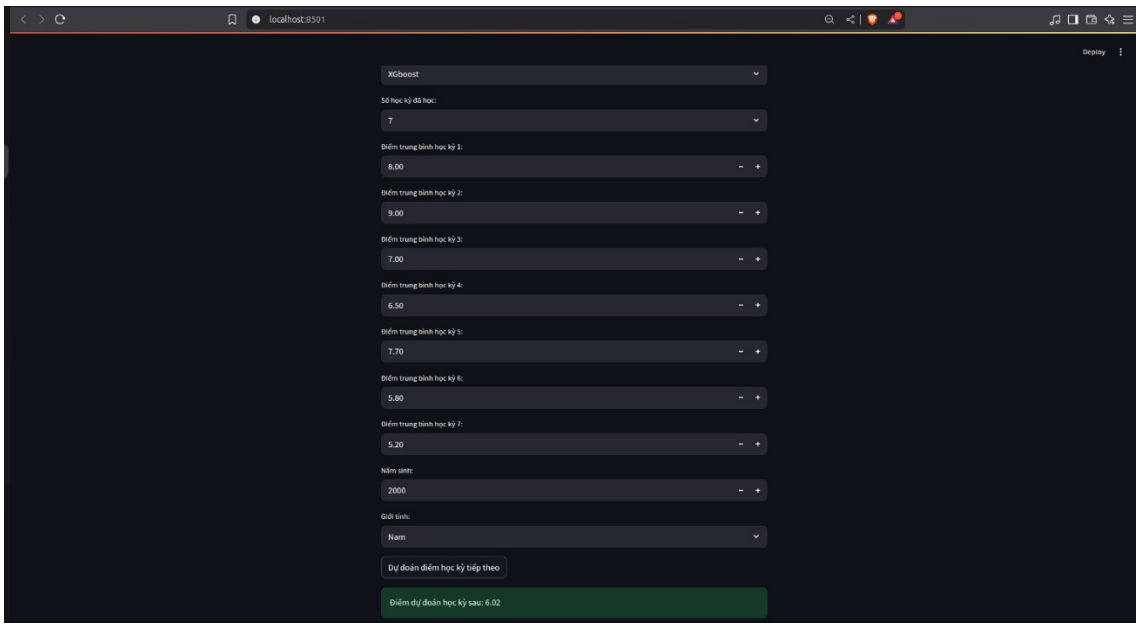
studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

Dự đoán điểm kì thứ 8 bằng dữ liệu 7 kì trước, sử dụng thuật toán Random Forest



Hình 16: Demo thuật toán Random Forest

Dự đoán điểm kì thứ 8 bằng dữ liệu 7 kì trước, sử dụng thuật toán XGBoost



Hình 17: Demo thuật toán XGBoost

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

CHƯƠNG 6. KẾT LUẬN

6.1. Tóm tắt đề tài

Nghiên cứu áp dụng các thuật toán học máy để dự đoán điểm trung bình học kỳ sinh viên từ dữ liệu lịch sử. Sau khi tiền xử lý dữ liệu, bao gồm loại bỏ ngoại lệ và tạo biến mới "dtbhk_x", các thuật toán như Random Forest, Linear Regression, XGBoost được đánh giá. Kết quả cho thấy mô hình có khả năng dự đoán tương đối chính xác, hỗ trợ nhà trường cải thiện hiệu quả đào tạo và giúp sinh viên định hướng học tập tốt hơn

6.2. Đóng góp của đề tài

Dự án mang lại giá trị thiết thực qua ứng dụng cho phép dự đoán điểm trung bình học kỳ dựa trên dữ liệu đầu vào từ sinh viên, giúp nhà trường và sinh viên định hướng học tập hiệu quả. Ứng dụng này không chỉ tối ưu hóa quy trình dự đoán mà còn khẳng định tiềm năng ứng dụng học máy vào lĩnh vực giáo dục.

6.3. Hướng phát triển đề tài

Dự án có thể được mở rộng bằng cách cải thiện chất lượng dữ liệu, bổ sung các đặc điểm như động lực học tập, hoạt động ngoại khóa để tăng độ chính xác mô hình. Áp dụng các thuật toán học máy tiên tiến như Deep Learning nhằm xử lý dữ liệu phức tạp hơn. Đồng thời, tích hợp hệ thống dự đoán vào nền tảng quản lý giáo dục để triển khai rộng rãi tại các trường đại học, nâng cao giá trị ứng dụng thực tiễn và hỗ trợ cá nhân hóa lộ trình học tập cho sinh viên.

studeersnel
Scan to open on Studeersnel
Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

TÀI LIỆU THAM KHẢO

[1] Ahmed, E. (2024). Student performance prediction using machine learning algorithms. *Applied Computational Intelligence and Soft Computing*, *2024*(1). https://doi.org/10.1155/2024/4067721

[2] Kabakchieva, D. (2013). Predicting student performance by using data mining methods for classification. *Cybernetics and Information Technologies*, *13*(1), 61–72. https://doi.org/10.2478/cait-2013-0006

[3] Sang, L. H., Hải, N. T., Điện, T. T., & Nghe, N. T. (2020). Dự báo kết quả học tập bằng kỹ thuật học sâu với mạng nơ-ron đa tầng. *Tạp chí Khoa học Đại học Cần Thơ*, *56*(3), 20-28. https://doi.org/10.22144/ctu.jvn.2020.049

studeersnel

Scan to open on Studeersnel

Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)

LINK GITHUB

https://github.com/Hatsuki9813/GPAPredictor.git

LINK THƯ MỤC GOOGLE DRIVE

Nhom_7 - Google Drive

studeersnel

Scan to open on Studeersnel

Downloaded by hoàng quý vo (quydeptrai123789@gmail.com)